

Análisis del rendimiento y la valoración salarial de futbolistas

Integración de datos y modelos de aprendizaje automático

Pablo Llorián González

Director: Marcos Sergio Pacheco dos Santos Lima Junior

El salario no depende solo del rendimiento

- Los salarios ocupan la mayor parte del presupuesto de un club.
- La ficha de un jugador puede corresponderse también a otros factores difíciles de medir.
- Si el rendimiento explica parte del salario, la diferencia entre lo que un jugador cobra y lo que su juego sugiere es información aprovechable.
- No existe ningún conjunto de datos que cruce rendimiento y salario.

EL SALARIO BRUTO ANUAL, EN CIFRAS

1,09 M€

salario mediano

2,19 M€

salario medio

72 M€

salario máximo observado

Una plataforma de valoración salarial

Objetivo general. Construir una plataforma de análisis de la valoración salarial de futbolistas a partir de su rendimiento.

01

¿Puede estimarse el salario bruto anual a partir del rendimiento y del contexto del jugador?

02

¿Pueden detectarse futbolistas sobrepagados e infrapagados respecto a ese rendimiento?

03

¿Es posible identificar jugadores de estilo similar mediante técnicas no supervisadas?

04

¿Puede integrarse todo en una herramienta explorable, útil para el scouting y la gestión?

Un pipeline de siete fases



Dos fuentes, seis ligas, seis temporadas

SOFAScore

Estadísticas acumuladas por temporada: en torno a 116 columnas que cubren participación, creación, finalización, pase, duelos, defensa y portería.

CAPOLOGY

Salario bruto anual, forzado a euros para hacer comparables las seis competiciones, junto con posición, edad, nacionalidad y club.

COMPETICIONES · TEMPORADAS 20/21 A 25/26

■ Premier League	Inglaterra
■ La Liga	España
■ Serie A	Italia
■ Bundesliga	Alemania
■ Ligue 1	Francia
■ Süper Lig	Turquía


36

combinaciones liga – temporada

20.316

observaciones jugador – temporada


El reto: no hay identificador común



- Las fuentes solo comparten el nombre del jugador y el de su equipo, y ambos difieren en grafía, acentuación y denominación del club.
- Cada etapa trabaja solo sobre lo que la anterior no resolvió, de la más automática a la más laboriosa.
- El fuzzy matching mide la distancia de Indel dentro de la propia plantilla, con cuatro niveles de confianza.
- Criterio conservador: antes dejar a un jugador sin salario que asignarle uno erróneo.

90,9 % de cobertura salarial en el conjunto depurado

El salario se comporta como una log-normal





Efecto del logaritmo

	lineal	log
Asimetría	6,04	-0,30
Curtosis	74,27	0,08

La transformación corrige la asimetría y estabiliza la varianza.

La liga y la edad marcan el contexto



- Jerarquía nítida entre competiciones y crecimiento sostenido de la mediana en las seis temporadas: liga y temporada son variables contextuales imprescindibles.
- Ninguna métrica de rendimiento supera por sí sola una correlación de 0,40 con el salario: no hay una variable estrella, sino la combinación de muchas.

Tres decisiones antes de modelar



Normalización por 90'

Las estadísticas pasan a medir rendimiento por unidad de tiempo y no volumen acumulado, de modo que jugadores con distinta participación resultan comparables.



Filtro de 450 minutos

Equivalen a cinco partidos completos. Por debajo, las estadísticas son ruido: un delantero que acierta en una racha breve aparenta un nivel que no tiene.



Dos preparaciones distintas

La regresión conserva liga y temporada. El espacio de estilo las descarta y reduce con PCA, para comparar a dos futbolistas aunque jueguen en contextos distintos.

20.307

observaciones depuradas



14.202

observaciones modelables

El filtro trae un efecto secundario favorable: los jugadores sin salario eran sobre todo canteranos y cedidos con poca participación, así que la cobertura salarial sube del 91 % a prácticamente el 100 %.

Modelo de regresión salarial

- Todas las particiones se hacen por jugador: sus temporadas caen siempre juntas y nunca se evalúa sobre alguien ya visto. Sin esa cautela el resultado se infla solo.
- Un 20 % de los jugadores se reserva como prueba y el ajuste se hace con validación cruzada agrupada sobre el resto.
- Se comparan Ridge, Lasso, Random Forest y XGBoost, y se optimiza XGBoost con Optuna.
- Segmentar por posición no mejora (0,564 frente a 0,559): se adopta un modelo global con la posición como una variable más.

Resultados sobre el conjunto de prueba

Modelo	R ²	MAE	RMSE
Combinado (con histórico)	0,72	0,45	0,64
Solo rendimiento (XGBoost)	0,59	0,61	0,78
Referencia lineal (Ridge)	0,56	0,62	0,80

El salto del 59 % al 72 % procede de incorporar la trayectoria salarial reciente. Quien no tiene histórico —debutantes o recién llegados de ligas no cubiertas— se predice con el modelo que solo usa rendimiento.


Los residuos como detector de anomalías

La diferencia entre el salario real y el estimado señala a quien cobra por encima o por debajo de lo que su rendimiento anticipa. Temporada 25/26, cifras en millones de euros.

Jugador	Equipo	Real	Estimado	Lectura
Omar Marmoush	Manchester City	17,77	3,30	Reputación y valor de mercado que el modelo no observa
Franco Mastantuono	Real Madrid	7,29	1,13	Expectativas de futuro por encima del rendimiento actual
N'Golo Kanté	Fenerbahçe	6,88	1,01	Fichas altas a veteranos de prestigio en ciertas ligas
Santi Cazorla	Real Oviedo	0,19	1,51	Regresa a su club de origen y acepta el salario mínimo
Pau Cubarsí	FC Barcelona	4,00	5,7	Central titular de élite en un grande con ficha aún de canterano

Un residuo grande no es un fallo del modelo, sino la señal de que ese salario responde a algo más que al rendimiento de una temporada. La interpretación final queda en manos del criterio experto.

El estilo de juego, sin mirar el salario



Similitud entre jugadores

PCA sobre las métricas normalizadas —17 componentes para jugadores de campo y 13 para porteros— y búsqueda de los vecinos más cercanos. Se descartan liga, temporada y nacionalidad: solo cuenta cómo juega.

Vinicius Júnior → Kvaratskhelia · Rafael Leão · Matheus Cunha

Rodri → Locatelli · Camavinga · Xhaka

Arquetipos por posición

K-means sobre el mismo espacio. El coeficiente de silueta señala dos grupos limpios por posición, con salarios medios coherentes.

■ Central de área	2,42 M€	■ Defensa lateral	1,89 M€
■ Medio creativo	4,47 M€	■ Medio de contención	1,77 M€
■ Rematador de área	2,98 M€	■ Atacante asociativo	2,86 M€

Todo integrado en una aplicación pública



Streamlit · cinco secciones: Buscador de reemplazos, Jugador, Ligas, Clubes y Comparador
<https://tfm-futbolistas.streamlit.app/>

Conclusiones y líneas futuras

Conclusiones

- El rendimiento explica parte del salario, no todo
- Lo no explicado tiene lógica futbolística
- La inercia salarial domina la predicción

Líneas futuras

- Ingesta continua y actualizada
- Más ligas y temporadas
- Incorporar el valor de mercado

Gracias por su atención

Plataforma: tfm-futbolistas.streamlit.app

Código: github.com/pablo29llori/TFM