



**Universidad
Europea**

UNIVERSIDAD EUROPEA DE ANDALUCÍA

ESCUELA POLITÉCNICA

**MÁSTER UNIVERSITARIO EN ANÁLISIS DE GRANDES
VOLÚMENES DE DATOS (BIG DATA)**

TRABAJO FIN DE MÁSTER

**ANÁLISIS DEL RENDIMIENTO Y LA
VALORACIÓN SALARIAL DE FUTBOLISTAS
MEDIANTE INTEGRACIÓN DE DATOS Y
MODELOS DE APRENDIZAJE AUTOMÁTICO**

PABLO LLORIÁN GONZÁLEZ

Dirigido por

MARCOS SERGIO PACHECO DOS SANTOS LIMA JUNIOR

CURSO 2025 - 2026

Análisis del rendimiento y la valoración salarial de futbolistas mediante integración de datos y modelos de aprendizaje automático

Pablo Llorián González



TÍTULO: ANÁLISIS DEL RENDIMIENTO Y LA VALORACIÓN SALARIAL DE FUTBOLISTAS MEDIANTE INTEGRACIÓN DE DATOS Y MODELOS DE APRENDIZAJE AUTOMÁTICO

AUTOR: PABLO LLORIÁN GONZÁLEZ

TITULACIÓN: MÁSTER UNIVERSITARIO EN ANÁLISIS DE GRANDES VOLÚMENES DE DATOS (BIG DATA)

DIRECTOR DEL PROYECTO: MARCOS SERGIO PACHECO DOS SANTOS LIMA JUNIOR

FECHA: [JULIO] de 2026

RESUMEN

El fútbol profesional se desarrolla en un entorno cada vez más condicionado por la disponibilidad de datos y por la presión económica de construir plantillas competitivas, donde los salarios suponen una parte relevante del presupuesto y no dependen únicamente del rendimiento deportivo. Este trabajo aborda, desde un enfoque cuantitativo, la estimación del salario de futbolistas profesionales a partir de su rendimiento, con el fin de detectar desajustes entre el salario real y el esperado y de proponer alternativas de perfil similar y menor coste. Ante la ausencia de un conjunto de datos que reúna esta información, se construye uno propio mediante *web scraping*, integrando las estadísticas de rendimiento de Sofascore y los datos salariales de Capology para seis grandes ligas europeas a lo largo de seis temporadas. La falta de un identificador común entre fuentes se resuelve con un emparejamiento por etapas basado en el nombre del jugador y su equipo.

Sobre el conjunto resultante, tras un análisis exploratorio y una fase de ingeniería de características que preparan los datos, se desarrolla un modelo de regresión basado en XGBoost que estima el salario bruto anual, con un coeficiente de determinación en torno al 72 % sobre jugadores no vistos. Sus residuos permiten identificar de forma sistemática futbolistas sobrepagados e infrapagados. El trabajo se complementa con técnicas no supervisadas que, a partir del estilo de juego, construyen un sistema de similitud entre jugadores y una tipificación en arquetipos por posición. Todos estos componentes se integran finalmente en una plataforma web interactiva, que permite consultar la valoración salarial de cada jugador, buscar reemplazos de menor coste y explorar ligas y clubes sin necesidad de conocimientos técnicos.

Los resultados confirman que el rendimiento explica una parte importante del salario, aunque no su totalidad, y que la fracción no explicada se **corresponde** con factores difíciles de medir, como la reputación o las expectativas de futuro. La solución desarrollada constituye así una herramienta útil de apoyo a la búsqueda de jugadores y a la gestión deportiva, que no pretende sustituir el criterio experto, sino complementarlo con un análisis estructurado y objetivo.

Palabras clave: aprendizaje automático, analítica deportiva, valoración salarial, integración de datos, *web scraping*, similitud entre jugadores.

ABSTRACT

Professional football takes place in an environment increasingly shaped by the availability of data and by the economic pressure of building competitive squads, where salaries account for a substantial share of the budget and do not depend solely on on-pitch performance. This project addresses, from a quantitative perspective, the estimation of professional footballers' salaries from their performance, aiming to detect gaps between actual and expected salary and to suggest alternatives with a similar profile and lower cost. As no existing dataset gathers this information, a custom one is built through web scraping, integrating performance statistics from Sofascore with salary data from Capology for six major European leagues over six seasons. The absence of a common identifier between sources is solved with a staged matching process based on player and team names.

On the resulting dataset, after an exploratory analysis and a feature engineering stage that prepare the data, an XGBoost regression model estimates the gross annual salary, reaching a coefficient of determination of around 72 % on unseen players. Its residuals systematically identify overpaid and underpaid footballers. The work is complemented with unsupervised techniques that, from playing style, build a player similarity system and a set of position-based archetypes. All these components are finally integrated into an interactive web platform that allows users to check each player's salary valuation, search for lower-cost replacements and explore leagues and clubs without any technical knowledge.

The results confirm that performance explains a large part of salary, though not all of it, and that the unexplained fraction corresponds to hard-to-measure factors such as reputation or future expectations. The resulting solution is therefore a useful support tool for player recruitment and sports management, one that does not aim to replace expert judgement but to complement it with a structured, objective analysis.

Keywords: machine learning, sports analytics, salary prediction, data integration, web scraping, player similarity.

Índice general

1. RESUMEN DEL PROYECTO	8
1.1. Contexto y justificación	8
1.2. Planteamiento del problema	8
1.3. Objetivos del proyecto	8
1.4. Resultados obtenidos	8
1.5. Estructura de la memoria	8
2. ANTECEDENTES / ESTADO DEL ARTE	9
2.1. Estado del arte	9
2.2. Contexto y justificación	10
2.3. Planteamiento del problema	11
3. OBJETIVOS	13
3.1. Objetivos generales	13
3.2. Objetivos específicos	13
3.3. Beneficios del proyecto	13
4. DESARROLLO DEL PROYECTO	15
4.1. Planificación del proyecto	15
4.2. Fundamentos teóricos	16
4.3. Desarrollo e implementación	23
4.3.1. Arquitectura del pipeline	23
4.3.2. Ingesta de datos	24
4.3.3. Preprocesamiento e integración	27
4.3.4. Análisis exploratorio de datos (EDA)	29
4.3.5. Feature engineering	43
4.3.6. Modelado y evaluación	46
4.3.7. Despliegue: plataforma interactiva	53
4.4. Resultados del proyecto	54
4.5. Recursos, presupuesto y viabilidad	55
4.6. Ética y compromiso social	56
5. DISCUSIÓN	57
5.1. Calidad de la predicción salarial	57
5.2. Detección de desajustes salariales	57
5.3. Limitaciones del estudio	58
5.4. Comparación con las expectativas	58
6. CONCLUSIONES	59
6.1. Conclusiones del trabajo	59
6.2. Conclusiones personales	59

7. FUTURAS LÍNEAS DE TRABAJO	60
Bibliografía	61
8. ANEXOS	63
8.1. Diccionario de variables	63
8.1.1. Diccionario de variables de Sofascore	63
8.1.2. Diccionario de variables de Capology	66

Índice de Figuras

4.1. Cronograma de las fases del proyecto.	15
4.2. Visión global del <i>pipeline</i> de datos.	24
4.3. Flujo del emparejamiento en cascada entre Sofascore y Capology.	28
4.4. Columnas con mayor porcentaje de valores nulos.	30
4.5. Cobertura temporal de las métricas de goles y asistencias esperadas.	31
4.6. Distribución del salario bruto anual en escala lineal y logarítmica.	33
4.7. Gráfico cuantil-cuantil del salario en escala lineal y logarítmica frente a la distribución normal.	33
4.8. Distribución del logaritmo del salario por liga.	34
4.9. Evolución de la media y la mediana salarial por temporada y crecimiento acumulado de la mediana.	34
4.10. Mediana salarial por liga y temporada.	35
4.11. Distribución de jugadores por posición.	35
4.12. Distribución del logaritmo del salario por posición.	36
4.13. Distribución de edades en el conjunto de datos.	36
4.14. Curva edad-salario: mediana del salario por edad.	37
4.15. Curvas edad-salario por posición.	37
4.16. Mediana del logaritmo del salario por posición y grupo de edad.	37
4.17. Nacionalidades más frecuentes en el conjunto de datos.	38
4.18. Salario mediano por nacionalidad restringido a las de mayor representación en la muestra.	38
4.19. Matriz de correlación entre las variables de rendimiento.	40
4.20. Dendrograma del agrupamiento jerárquico de las variables de rendimiento según su correlación.	41
4.21. Varianza explicada por componente y varianza acumulada del análisis de componentes principales sobre las variables de rendimiento.	42
4.22. Distribución de los minutos disputados por temporada.	44
4.23. Varianza explicada acumulada del análisis de componentes principales para jugadores de campo y porteros.	46
4.24. Importancia de las variables en el modelo con histórico (izquierda) y coeficientes del modelo lineal de referencia (derecha).	48
4.25. Proyección del espacio de estilo sobre sus dos primeras componentes, con un jugador de referencia y sus perfiles más próximos.	51
4.26. Coeficiente de silueta por número de grupos para los delanteros.	52
4.27. Proyección bidimensional de los jugadores de campo, coloreados por posición y por arquetipo.	52

Índice de Tablas

4.1. Competiciones analizadas, todas con las temporadas 20/21 a 25/26.	25
4.2. Principales categorías de métricas de rendimiento extraídas de Sofascore. . . .	26
4.3. Niveles del <i>fuzzy matching</i> y su política de aceptación.	29
4.4. Cobertura salarial (%) por liga y temporada tras la depuración.	31
4.5. Estadísticos descriptivos del salario bruto anual.	32
4.6. Asimetría y curtosis del salario en escala lineal y logarítmica.	32
4.7. Número de pares de variables de rendimiento por umbral de correlación absoluta.	39
4.8. Principales bloques temáticos de variables identificados por el agrupamiento jerárquico.	41
4.9. Variables de rendimiento más correlacionadas con el logaritmo del salario en cada posición.	42
4.10. Cobertura salarial (%) por liga y temporada tras el filtrado.	44
4.11. Ejemplos de jugadores más próximos en el espacio de similitud.	46
4.12. Rendimiento de los modelos sobre el conjunto de prueba.	48
4.13. Ejemplos de jugadores con mayor desajuste salarial en la temporada 25/26 (salarios en millones de euros).	49
4.14. Reemplazos de perfil similar a Vinicius Júnior (ahorro en M€).	50
4.15. Ejemplos de jugadores más próximos en el espacio de estilo para algunos futbolistas de referencia.	50
4.16. Arquetipos identificados por posición y salario medio de cada uno.	52
8.1. Diccionario de las variables extraídas de Sofascore.	63
8.2. Diccionario de los campos obtenidos de Capology.	66

Capítulo 1. RESUMEN DEL PROYECTO

Este capítulo ofrece una panorámica general del trabajo, sin entrar en el detalle de cada fase. Se resume el problema abordado, su planteamiento, los objetivos, los principales resultados y la organización de la memoria.

1.1 Contexto y justificación

El fútbol profesional se desarrolla en un entorno cada vez más condicionado por la disponibilidad de datos y por la presión económica de construir plantillas competitivas, donde los salarios representan una parte muy relevante del presupuesto. En este contexto, la remuneración de un jugador no depende únicamente de su rendimiento, lo que abre la oportunidad de estudiar esa relación desde un enfoque cuantitativo y de detectar posibles desajustes entre lo que un futbolista cobra y lo que su juego sugiere.

1.2 Planteamiento del problema

El trabajo se pregunta hasta qué punto el salario bruto anual de un futbolista puede explicarse a partir de su rendimiento y, sobre esa base, si es posible detectar jugadores sobrepagados o infrapagados y proponer alternativas de perfil similar y menor coste. Se trata de una cuestión del ámbito científico-técnico, orientada a aplicar técnicas de integración de datos y aprendizaje automático al análisis deportivo.

1.3 Objetivos del proyecto

El objetivo general es construir una plataforma de análisis de la valoración salarial de futbolistas basada en su rendimiento. Los objetivos específicos recorren todo el ciclo del proyecto, desde la ingesta de datos de fuentes dispares y su integración y depuración hasta el desarrollo de un modelo de regresión salarial, un sistema de similitud entre jugadores y una tipificación en arquetipos, culminando en el despliegue de una aplicación interactiva. Los objetivos se detallan en el Capítulo 3.

1.4 Resultados obtenidos

El modelo de regresión estima el salario con una capacidad explicativa en torno al 72 % sobre jugadores no vistos. A partir de sus residuos se detectan los jugadores cuya remuneración se aleja de la esperada, con casos coherentes con el conocimiento futbolístico. El sistema de similitud y los arquetipos capturan el estilo de juego, y todo ello se integra en una plataforma interactiva para consultar la valoración salarial, buscar reemplazos y explorar ligas y clubes.

1.5 Estructura de la memoria

La memoria se organiza en ocho capítulos. Tras este resumen, el Capítulo 2 revisa los antecedentes y el estado del arte, y el Capítulo 3 detalla los objetivos. El Capítulo 4, núcleo del trabajo, recoge la planificación, los fundamentos teóricos, la implementación de cada fase del pipeline y los resultados. El Capítulo 5 los somete a una lectura crítica, el Capítulo 6 recoge las conclusiones y el Capítulo 7 plantea las futuras líneas. Por último, los anexos (Capítulo 8) reúnen el material complementario, como el diccionario de variables de las fuentes empleadas.

Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE

En este capítulo se presenta el contexto del proyecto, revisando brevemente la analítica deportiva moderna, los modelos de valoración económica de futbolistas y el problema concreto que se aborda en el trabajo.

2.1 Estado del arte

La aplicación de técnicas cuantitativas al análisis del fútbol ha crecido de forma notable en los últimos años. Aunque el criterio de los expertos sigue siendo fundamental en los procesos de *scouting* y toma de decisiones, la disponibilidad de datos ha permitido complementar estas evaluaciones con indicadores objetivos de rendimiento. Tradicionalmente, el análisis de jugadores se basaba en métricas simples como goles, asistencias o minutos jugados. Estas variables siguen siendo útiles por su claridad, pero presentan limitaciones cuando se analizan de forma aislada, especialmente en un deporte como el fútbol, donde los eventos decisivos son escasos y están condicionados por el contexto.

Dentro de esta evolución han ganado relevancia las métricas avanzadas, como los goles esperados (xG) y las asistencias esperadas (xA). Estas métricas buscan estimar la calidad de las acciones ofensivas en lugar de centrarse únicamente en su resultado final. La idea de los goles esperados surge precisamente como respuesta a una limitación propia del fútbol: el gol es un suceso poco frecuente y, por tanto, métricas simples como el número de disparos, centros o pases al área no siempre reflejan de forma adecuada la calidad real de las ocasiones generadas. Así, el xG asigna a cada disparo una probabilidad de acabar en gol a partir de las condiciones en que se produce (la posición, el ángulo o el tipo de remate), mientras que el xA estima la probabilidad de que un pase acabe en asistencia [1].

La analítica deportiva reciente también ha ampliado su enfoque más allá de las acciones directamente registradas con balón. En deportes de equipo como el fútbol, el rendimiento individual y colectivo depende en gran parte de los movimientos sin balón, la ocupación de espacios y las interacciones entre jugadores. La disponibilidad de datos espaciotemporales ha permitido estudiar este tipo de comportamientos con mayor detalle, dando lugar a modelos que valoran no solo la acción final, sino también las ventajas posicionales que se generan antes de ella. En esta línea, algunos trabajos han propuesto cuantificar oportunidades creadas sin balón, valorando situaciones en las que un jugador genera una opción de peligro aunque finalmente no reciba el pase [2].

También se han desarrollado distintos enfoques para estimar el valor económico de los jugadores en el mercado de fichajes. Plataformas como Transfermarkt [3] y organismos como el CIES Football Observatory [4] proporcionan estimaciones basadas en variables deportivas y económicas, como la edad, el rendimiento reciente, la experiencia competitiva, la duración del contrato o el contexto del club. No obstante, estos valores no deben confundirse con el salario: el valor de mercado aproxima el precio potencial de una transferencia, mientras que el salario representa la remuneración pactada entre jugador y club. Además, el precio final de un futbolista puede alejarse de su valor estimado por factores subjetivos del mercado, como

la demanda de determinados perfiles, la capacidad financiera de los clubes, la competencia entre compradores o las expectativas deportivas asociadas al jugador [5]. Desde este punto de vista, el salario puede entenderse como una variable relacionada con la productividad del futbolista, aunque también condicionada por elementos difíciles de medir, como pueden ser la reputación, el potencial o la capacidad de negociación del jugador y su entorno.

En los últimos años, el uso de técnicas de aprendizaje automático ha permitido avanzar en la predicción de valores económicos en el fútbol. Se han utilizado modelos de regresión, árboles de decisión, métodos de *ensemble* y redes neuronales para estimar tanto valores de mercado como salarios [6]. Estos enfoques permiten capturar relaciones complejas entre variables y, en algunos casos, incorporar herramientas de interpretabilidad para analizar la importancia de cada factor en la predicción [7].

El presente proyecto se sitúa en esta línea, pero se centra en la estimación del salario bruto anual de los futbolistas en lugar de su valor de mercado. Esta elección responde a que el salario representa un coste directo para los clubes y resulta especialmente relevante en la planificación deportiva. Se implementa un modelo de regresión salarial que se complementa con un sistema de similitud entre jugadores y la identificación de arquetipos por posición, configurando así una herramienta de apoyo a la toma de decisiones deportivas.

2.2 Contexto y justificación

El fútbol profesional actual se desarrolla en un entorno cada vez más condicionado por la disponibilidad de información y por la presión económica asociada a la construcción de plantillas competitivas. Los clubes deben tomar decisiones sobre fichajes, renovaciones o ventas en un mercado donde los salarios representan una parte muy importante del presupuesto y donde los errores de planificación pueden tener consecuencias deportivas y financieras importantes. En este contexto, resulta especialmente útil disponer de herramientas que permitan analizar de forma conjunta el rendimiento deportivo y el coste salarial de los jugadores.

Una de las principales dificultades en la valoración de futbolistas es que el salario no depende únicamente del rendimiento observado. Factores como la trayectoria previa, la edad, la posición, el club, la liga, el poder negociador, la reputación o las expectativas de rendimiento futuro pueden influir en la remuneración final. Esto provoca que existan jugadores con salarios elevados cuyo rendimiento reciente puede no justificar completamente su coste, así como futbolistas con buen rendimiento y salarios relativamente bajos que pueden representar oportunidades de mercado. Para mejorar la eficiencia en la planificación deportiva, es esencial detectar este tipo de desajustes.

El presente proyecto se justifica precisamente por la necesidad de estudiar esta relación entre rendimiento y salario desde un enfoque cuantitativo. A diferencia de otros trabajos centrados en el valor de mercado o en el precio de traspaso, aquí se toma como referencia el salario bruto anual del jugador. Esta elección permite orientar el análisis hacia el coste recurrente que asume el club por disponer de un futbolista en su plantilla, una variable especialmente importante en la gestión económica de los equipos.

Para ello, el proyecto integra datos de rendimiento y salarios de jugadores pertenecientes a seis ligas europeas durante seis temporadas. Esta amplitud permite analizar perfiles de

futbolistas en distintos contextos competitivos y temporales, evitando que el estudio quede limitado a una única liga o temporada. Además, la combinación de información deportiva y económica permite construir una base de datos orientada no solo a la descripción del rendimiento, sino también a la estimación de salarios esperados y a la detección de posibles desviaciones entre salario real y salario estimado.

El carácter diferencial del proyecto reside en su doble enfoque. Por un lado, un modelo de regresión salarial que predice el salario de cada jugador a partir de sus estadísticas deportivas. Por otro, un conjunto de técnicas no supervisadas que perfilan a los futbolistas según su estilo de juego, mediante un sistema de similitud entre jugadores y una tipificación en arquetipos por posición. La combinación de ambas perspectivas permite pasar de una predicción individual a una herramienta de apoyo al *scouting*, capaz de señalar jugadores potencialmente sobrepagados, infrapagados o alternativas de menor coste para un perfil determinado.

Finalmente, la implementación se materializa en una plataforma interactiva de visualización y consulta. De este modo, el proyecto no se limita al entrenamiento de modelos, sino que transforma los datos y resultados en una herramienta explorable para el análisis de jugadores, clubes y ligas.

2.3 Planteamiento del problema

El problema abordado en este trabajo consiste en analizar hasta qué punto el salario de un futbolista profesional puede explicarse a partir de su rendimiento deportivo. Para ello, se parte de una base de datos formada por observaciones jugador-temporada, donde cada registro contiene información estadística del jugador, variables contextuales y su salario bruto anual. El objetivo principal es construir un modelo capaz de estimar un salario esperado y comparar dicha estimación con el salario real observado.

Desde un punto de vista técnico, el proyecto combina aprendizaje supervisado y no supervisado. En primer lugar, se plantea una tarea de regresión en la que, para cada jugador i , se dispone de un conjunto de variables explicativas X_i y de una variable objetivo y_i , correspondiente al salario bruto anual. El modelo busca aprender una función f tal que:

$$\hat{y}_i = f(X_i),$$

donde $\hat{y}_i$ representa el salario estimado. La diferencia entre salario real y salario estimado permite identificar posibles desviaciones salariales, es decir, jugadores cuya remuneración se sitúa por encima o por debajo de lo que cabría esperar según sus estadísticas observables.

De forma complementaria, se utilizan técnicas no supervisadas para analizar perfiles deportivos. Por un lado, se construye un sistema de similitud entre jugadores, orientado a encontrar futbolistas con características comparables. Por otro, se generan arquetipos por posición, que permiten agrupar jugadores según patrones comunes de rendimiento y estilo de juego. Esta aproximación facilita interpretar a cada futbolista no solo por su salario estimado, sino también por el tipo de perfil de futbolista que representa dentro de su posición.

A partir de este planteamiento, el proyecto se guía por las siguientes preguntas de investiga-

ción:

- ¿Es posible estimar el salario bruto anual de un futbolista a partir de sus estadísticas de rendimiento y variables contextuales?
- ¿Pueden detectarse jugadores potencialmente sobrepagados o infrapagados en relación con su rendimiento observable?
- ¿Es posible identificar futbolistas similares y perfiles de juego comparables mediante técnicas no supervisadas?
- ¿Cómo puede integrarse este análisis en una plataforma interactiva útil para tareas de *scouting* y gestión de plantillas?

En definitiva, el trabajo plantea una solución analítica que combina la integración de datos, su análisis exploratorio y preparación, la regresión salarial, la similitud entre jugadores, la identificación de arquetipos y la visualización interactiva. Su finalidad no es sustituir el criterio experto, sino proporcionar una herramienta complementaria para explorar información deportiva y económica de forma estructurada.

Capítulo 3. OBJETIVOS

En este capítulo se detallan los objetivos que guían el trabajo. Se parte de un objetivo general, que define el propósito global del proyecto, y se desglosa en una serie de objetivos específicos que se corresponden con las distintas fases del desarrollo. Se cierra con los beneficios que se esperan de la solución propuesta.

3.1 Objetivos generales

El objetivo general del proyecto es construir una plataforma de análisis de la valoración salarial de futbolistas a partir de su rendimiento deportivo. Se persigue integrar en una única solución datos de rendimiento y salario de distintas fuentes, estimar el salario esperado de cada jugador, detectar desajustes entre el salario real y el estimado, e identificar futbolistas de perfil comparable. El propósito no es sustituir el criterio de los expertos, sino ofrecer una herramienta complementaria que permita explorar de forma estructurada la relación entre rendimiento y remuneración, orientada al apoyo en la toma de decisiones deportivas.

3.2 Objetivos específicos

El objetivo general se concreta en los siguientes objetivos específicos, alineados con las fases del pipeline de datos:

- Realizar la ingesta multi-fuente de los datos, obteniendo mediante *web scraping* las estadísticas de rendimiento y la información salarial de los jugadores de seis grandes ligas europeas a lo largo de seis temporadas, a partir de plataformas que solo los publican para su consulta visual.
- Integrar y depurar la información, cruzando las fuentes en una única tabla maestra y resolviendo el problema de la ausencia de un identificador común entre ellas mediante un emparejamiento por nombre de jugador y equipo.
- Llevar a cabo un análisis exploratorio que permita comprender la estructura del conjunto de datos, caracterizar la variable objetivo y estudiar su relación con las variables de rendimiento y contextuales, orientando las decisiones posteriores de modelado.
- Desarrollar un modelo de regresión que estime el salario esperado de cada jugador a partir de su rendimiento y que, a través de sus residuos, permita detectar futbolistas sobrepagados o infrapagados.
- Construir, mediante técnicas no supervisadas, un sistema que identifique jugadores de estilo parecido y una tipificación en arquetipos por posición que caractericen el perfil de juego de cada futbolista.
- Desplegar los resultados en una aplicación web interactiva y accesible, que traduzca los modelos en una herramienta explorable de consulta y análisis.

3.3 Beneficios del proyecto

La solución desarrollada aporta valor a distintos perfiles del ámbito futbolístico. Para los clubes, constituye una herramienta de apoyo al *scouting* y a la negociación, al señalar jugadores cuyo salario se aparta de su rendimiento y proponer alternativas de perfil similar y menor coste, lo que resulta especialmente útil en la planificación deportiva y económica de las plantillas.

Para los agentes y analistas, ofrece una referencia objetiva con la que contrastar la valoración de un futbolista. Y para los aficionados, brinda una vía accesible para explorar el rendimiento y la situación salarial de jugadores, clubes y ligas. En conjunto, el proyecto busca acercar el análisis de datos deportivos a un público amplio, sin exigir conocimientos técnicos para su uso.

Capítulo 4. DESARROLLO DEL PROYECTO

En este capítulo se describe el desarrollo del proyecto. Comienza con la planificación y la metodología de trabajo seguida. A continuación se exponen los fundamentos teóricos de algunas de las técnicas y conceptos empleados. Después se detalla la implementación de cada una de las fases que componen la solución, desde la ingesta de datos hasta el despliegue de la plataforma interactiva. Por último, se presentan e interpretan los resultados obtenidos.

4.1 Planificación del proyecto

El desarrollo ha seguido una metodología iterativa estructurada por fases, en la que el resultado de cada etapa sirve de entrada para la siguiente. Este planteamiento es bastante común en un proyecto de ciencia de datos, ya que las decisiones tomadas durante la preparación de los datos condicionan directamente el modelado y donde no es inusual retroceder a una fase previa para corregir el trabajo ya realizado.

El proyecto se ha distribuido en siete fases consecutivas que abarcan desde la obtención de los datos hasta el despliegue de la plataforma final: ingesta de datos, preprocesamiento e integración, análisis exploratorio, ingeniería de características, modelado y evaluación, y construcción de la aplicación interactiva. El cronograma asociado a estas fases se recoge en la Figura 4.1.




Figura 4.1. Cronograma de las fases del proyecto.

El control de versiones se ha gestionado con **Git** y **GitHub**. Cada avance relevante se ha registrado en una confirmación con un mensaje descriptivo de los cambios, lo que ha mantenido un historial claro y trazable del trabajo y ha facilitado su seguimiento por parte del tutor.

El desarrollo se ha apoyado en cuadernos Jupyter para el trabajo exploratorio e iterativo de cada fase. Los archivos se han organizado en una estructura de carpetas que sigue las etapas del *pipeline*, separando la obtención de datos, su procesamiento, el modelado y la aplicación interactiva.

4.2 Fundamentos teóricos

Antes de detallar la implementación de cada fase, conviene introducir los conceptos y técnicas en los que se apoya el desarrollo del proyecto. Esta sección reúne los fundamentos teóricos de mayor relevancia, con el propósito de que las decisiones descritas más adelante puedan interpretarse a partir de una base común. No se pretende una revisión exhaustiva de cada método, sino presentar las nociones necesarias para comprender su aplicación en el contexto del trabajo.

Definición 4.1 (Ingesta de datos). Primera fase de un proyecto de ciencia de datos, consistente en la obtención de la información en bruto desde sus fuentes de origen y su incorporación a un entorno controlado sobre el que trabajar. Suele clasificarse según la frecuencia con que se recogen los datos, distinguiendo entre la ingesta por lotes (*batch*) y en tiempo real (*streaming*), y según la forma de obtenerlos, ya sea mediante interfaces de programación (API), lectura de ficheros o *web scraping* [8].

En este proyecto, la información necesaria no se encuentra disponible en ningún conjunto de datos ya publicado, sino dispersa en plataformas que la ofrecen únicamente para consulta visual. Ante este escenario, la ingesta se resuelve mediante *web scraping* por lotes.

Definición 4.2 (Web scraping). Técnica de extracción y recolección automatizada de datos a partir de páginas web. El procedimiento recorre el contenido de las páginas, localiza los elementos de interés y los estructura en un formato tabular explotable, que posteriormente puede almacenarse en ficheros (JSON, CSV, XML) o volcarse a una base de datos para su uso posterior [9].

Este enfoque resulta especialmente útil cuando los datos deben reunirse sobre la marcha para el desarrollo de un modelo y no existe una vía de descarga estructurada, como ocurre con las fuentes empleadas en este trabajo.

Tras el preprocesamiento e integración y con una vez disponible el conjunto de datos, su análisis y posterior modelado se apoyan en una serie de conceptos estadísticos que conviene introducir con antelación.

Definición 4.3 (Distribución log-normal). Una variable aleatoria positiva X sigue una distribución *log-normal* cuando su logaritmo se distribuye de forma normal, es decir, cuando $\ln(X) \sim \mathcal{N}(\mu, \sigma^2)$. Su función de densidad es

$$f(x) = \frac{1}{x \sigma \sqrt{2\pi}} \exp\left(-\frac{(\ln x - \mu)^2}{2\sigma^2}\right), \quad x > 0.$$

Es habitual en fenómenos económicos como salarios, rentas o capitalización bursátil, caracterizados por una fuerte asimetría a la derecha, donde la mayoría de las observaciones se concentran en valores bajos y una cola larga recoge unos pocos valores muy elevados. La distribución salarial suele ajustarse bien a este modelo, y la transformación logarítmica de la variable produce una distribución aproximadamente simétrica, más adecuada para el análisis y el modelado [10].

La forma de una distribución puede caracterizarse formalmente mediante diversos indicado-

res, empleados más adelante en el análisis de la variable objetivo.

Definición 4.4 (Asimetría). La *asimetría* (*skewness*), denotada por γ_1 , mide la falta de simetría de una distribución respecto a su media. Su interpretación es la siguiente:

$$\begin{cases} \gamma_1 = 0, & \text{distribución simétrica,} \\ \gamma_1 > 0, & \text{cola derecha más larga,} \\ \gamma_1 < 0, & \text{cola izquierda más larga.} \end{cases}$$

Definición 4.5 (Curtosis). La *curtosis* (*kurtosis*), denotada por γ_2 , mide el peso de las colas de una distribución tomando como referencia la distribución normal. Su interpretación es la siguiente:

$$\begin{cases} \gamma_2 = 0, & \text{colas semejantes a las de una distribución normal,} \\ \gamma_2 > 0, & \text{colas más pesadas y mayor presencia de valores extremos,} \\ \gamma_2 < 0, & \text{colas más ligeras.} \end{cases}$$

Junto a estos indicadores de forma, se utiliza un criterio objetivo para identificar observaciones atípicas.

Definición 4.6 (Criterio del rango intercuartílico). Regla habitual para la identificación de valores atípicos (*outliers*). Sean Q_1 y Q_3 el primer y el tercer cuartil de una variable y $\text{IQR} = Q_3 - Q_1$ su rango intercuartílico. A partir de ellos se definen las cotas

$$L = Q_1 - k \cdot \text{IQR}, \quad U = Q_3 + k \cdot \text{IQR}, \quad k = 1,5,$$

y se considera atípica toda observación x que quede fuera del intervalo $[L, U]$, es decir, tal que $x < L$ o $x > U$. El factor $k = 1,5$ es el valor habitual, y usar uno mayor (por ejemplo $k = 3$) conserva solo los *outliers* más extremos. El criterio funciona bien en distribuciones aproximadamente simétricas, pero en las muy asimétricas pierde utilidad, ya que tiende a marcar como atípica la cola natural de la distribución.

Estos indicadores numéricos se complementan con representaciones gráficas que permiten examinar visualmente la forma de una distribución.

Definición 4.7 (Diagrama de caja). El *diagrama de caja* (*boxplot*) resume una distribución a partir de sus cuartiles. La caja abarca del primer al tercer cuartil, con una línea interior en la mediana, y los bigotes se extienden hasta las observaciones más alejadas que permanecen dentro del criterio del rango intercuartílico; los puntos situados fuera de ese margen se representan individualmente como valores atípicos.

Definición 4.8 (Gráfico cuantil-cuantil). El *gráfico cuantil-cuantil* (*Q-Q plot*) contrasta de forma visual una distribución empírica con una distribución teórica de referencia, habitualmente la normal, enfrentando sus cuantiles. Si ambas coinciden, los puntos se alinean sobre la dia-

gonal; las desviaciones respecto a ella revelan discrepancias, y su localización indica si estas se producen en el centro o en las colas de la distribución.

El estudio de las relaciones entre variables, y de estas con la variable objetivo, requiere además un conjunto de medidas de dependencia y de técnicas de análisis multivariante.

Definición 4.9 (Coeficiente de correlación de Pearson). Mide la dependencia *lineal* entre dos variables continuas. Se define como el cociente entre su covarianza y el producto de sus desviaciones típicas,

$$r_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} \in [-1, 1].$$

Su interpretación según el valor que toma es la siguiente:

$$r_{XY} = \begin{cases} +1, & \text{relación lineal positiva perfecta,} \\ 0, & \text{ausencia de relación lineal,} \\ -1, & \text{relación lineal negativa perfecta.} \end{cases}$$

Es sensible a los valores atípicos y no detecta relaciones no lineales.

Definición 4.10 (Coeficiente de correlación de Spearman). Mide la dependencia *monótona* entre dos variables, es decir, la tendencia de una a crecer o decrecer con la otra aunque la relación no sea lineal. Se obtiene aplicando el coeficiente de Pearson sobre los rangos de las observaciones, lo que lo hace más robusto frente a valores atípicos que su análogo lineal. En ausencia de empates admite la expresión

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \in [-1, 1],$$

donde d_i es la diferencia entre los rangos de la observación i en cada variable y n el número de observaciones.

Definición 4.11 (Información mutua). Medida de dependencia estadística de carácter general entre dos variables, procedente de la teoría de la información. Para dos variables discretas se define como

$$I(X; Y) = \sum_x \sum_y p(x, y) \log \frac{p(x, y)}{p(x)p(y)},$$

donde $p(x, y)$ es su distribución conjunta y $p(x)$, $p(y)$ las marginales. A diferencia de los coeficientes de correlación, capta cualquier tipo de relación, también las no monótonas. Es siempre no negativa y se anula únicamente cuando las dos variables son independientes, es decir, cuando $p(x, y) = p(x)p(y)$.

Las definiciones estadísticas y las representaciones gráficas anteriores siguen la formulación habitual de los manuales de estadística descriptiva [11], [12].

Más allá de la relación entre pares de variables, el estudio de la estructura conjunta de un gran número de ellas requiere técnicas de análisis multivariante, empleadas más adelante para examinar y resumir el conjunto de variables de rendimiento.

Definición 4.12 (Agrupamiento jerárquico). Técnica de aprendizaje no supervisado que agrupa un conjunto de elementos según su parecido, sin necesidad de decidir de antemano cuántos grupos formar. Cada elemento empieza como un grupo propio y los más parecidos se van uniendo poco a poco hasta quedar todos en uno solo. El proceso se representa mediante un *dendrograma*, un diagrama en forma de árbol en el que, cortando a distintas alturas, se obtiene el número de grupos deseado.

Definición 4.13 (Análisis de componentes principales). Técnica de reducción de la dimensionalidad que transforma un conjunto de variables posiblemente correlacionadas en un número menor de variables no correlacionadas, denominadas *componentes principales*. Cada componente es una combinación lineal de las variables originales, obtenida a partir de los autovectores de la matriz de covarianzas, y su autovalor asociado λ_k coincide con la varianza que recoge. Los componentes se ordenan de mayor a menor varianza, de modo que el k -ésimo explica una proporción

$$\frac{\lambda_k}{\sum_j \lambda_j}$$

del total. Esto permite estimar la dimensión intrínseca de un conjunto de datos y representarlo con menos variables reteniendo la mayor parte de su variabilidad.

Tanto el agrupamiento jerárquico como el análisis de componentes principales se emplean más adelante para estudiar la estructura de las variables de rendimiento, siguiendo la formulación habitual del aprendizaje estadístico [13].

Concluido el análisis exploratorio, la fase de ingeniería de características (*feature engineering*) transforma los datos depurados en las variables concretas que alimentan cada modelo. Se trata de un paso decisivo en todo proyecto de aprendizaje automático, en el que se seleccionan, combinan y transforman las variables de partida para obtener representaciones más adecuadas al problema, capaces de mejorar el rendimiento de los modelos [14]. A continuación se introducen las transformaciones empleadas en esta fase.

Definición 4.14 (Normalización por noventa minutos). Transformación propia de la analítica futbolística que expresa una estadística acumulada como una tasa por cada noventa minutos de juego, la duración de un partido. Se obtiene dividiendo el valor total entre los minutos disputados y multiplicando por noventa. Permite comparar de forma justa a jugadores con distinto tiempo de juego, al medir su rendimiento por unidad de tiempo en lugar de en términos absolutos.

Definición 4.15 (Codificación *one-hot*). Técnica que transforma una variable categórica con posibles categorías $\{c_1, \dots, c_K\}$ en un conjunto de K variables binarias. Una observación de valor x se representa mediante el vector $(\mathbf{1}[x = c_1], \dots, \mathbf{1}[x = c_K])$, cuya componente k -ésima vale uno cuando la observación pertenece a la categoría c_k y cero en caso contrario. Permite que los modelos traten cada categoría de forma independiente, sin imponer entre ellas un orden que no existe.

Definición 4.16 (Estandarización robusta). Reescalado de las variables para situarlas en un rango comparable, empleando la mediana y el rango intercuartílico en lugar de la media y la

desviación típica. Para una variable x , cada valor se transforma del siguiente modo:

$$x' = \frac{x - \text{mediana}(x)}{\text{IQR}(x)}.$$

Al apoyarse en medidas resistentes a los valores extremos, resulta especialmente adecuada cuando los datos presentan una fuerte asimetría o valores atípicos.

La codificación de las variables categóricas y el escalado de las numéricas son pasos habituales en la ingeniería de características, ampliamente tratados en la literatura sobre preparación de datos para modelos predictivos [15].

El núcleo del trabajo se apoya en técnicas de aprendizaje automático, la disciplina que estudia cómo los sistemas aprenden patrones a partir de los datos en lugar de seguir reglas programadas de antemano. Estas técnicas se dividen en dos grandes familias según la naturaleza del problema: el aprendizaje supervisado y el no supervisado, que se distinguen por la presencia o ausencia de una variable respuesta conocida.

En el aprendizaje supervisado se dispone de un conjunto de ejemplos etiquetados $\{(x_i, y_i)\}_{i=1}^n$, donde cada x_i reúne las variables de entrada y y_i es la respuesta conocida, y el objetivo es aprender una función $f: \mathcal{X} \rightarrow \mathcal{Y}$ que aproxime la relación entre ambas para predecir la respuesta en casos nuevos, como ocurre al estimar el salario de un jugador a partir de su rendimiento. En el aprendizaje no supervisado solo se dispone de las entradas $\{x_i\}_{i=1}^n$, sin ninguna respuesta asociada, y en lugar de predecir se busca descubrir la estructura oculta de los datos, como los perfiles o los tipos de jugador. El trabajo recurre a ambas familias, y a continuación se introducen los conceptos teóricos que sustentan la fase de modelado.

Definición 4.17 (Regresión). Tarea de aprendizaje supervisado cuyo objetivo es predecir una variable numérica continua $y \in \mathbb{R}$ a partir de un vector de variables explicativas $x \in \mathbb{R}^p$. A partir de ejemplos con el valor conocido, el modelo aprende una función $f: \mathbb{R}^p \rightarrow \mathbb{R}$ que relaciona las variables de entrada con la salida, de modo que la predicción para una nueva observación es $\hat{y} = f(x)$.

Una vez entrenado un modelo de regresión, es necesario cuantificar hasta qué punto las predicciones se aproximan a los valores reales.

Definición 4.18 (Métricas de evaluación en regresión). Dadas n observaciones con valores reales y_i , predicciones $\hat{y}_i$ y media $\bar{y}$, las métricas más habituales son el error absoluto medio (MAE), la raíz del error cuadrático medio (RMSE) y el coeficiente de determinación (R^2),

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2},$$
$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}.$$

El MAE promedia la magnitud de los errores sin atender a su signo, mientras que el RMSE penaliza con más fuerza los errores grandes al elevarlos al cuadrado. El R^2 mide la proporción de la variabilidad de la variable objetivo que el modelo explica, y alcanza su valor máximo,

uno, en una predicción perfecta.

Un riesgo permanente al ajustar un modelo es que se adapte en exceso a los datos con los que aprende y pierda capacidad de generalizar. Esto sobreajuste se denomina *overfitting* y motiva el uso de la regularización.

Definición 4.19 (Regularización). Conjunto de técnicas que limitan la complejidad de un modelo para evitar el sobreajuste a los datos de entrenamiento. En los modelos lineales, se añade a la función de error una penalización sobre el tamaño de los coeficientes β_j , de la forma

$$\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \Omega(\beta),$$

donde λ regula la intensidad de la penalización. Según cómo se define $\Omega(\beta)$ se obtienen las dos variantes habituales, la regresión *Ridge*, con penalización **L2** (cuadrática), y *Lasso*, con penalización **L1** (en valor absoluto), que además anula coeficientes poco relevantes,

$$\Omega_{\text{Ridge}}(\beta) = \|\beta\|_2^2 = \sum_j \beta_j^2, \quad \Omega_{\text{Lasso}}(\beta) = \|\beta\|_1 = \sum_j |\beta_j|.$$

Frente a estos modelos lineales, otra familia de gran uso construye las predicciones a partir de reglas sobre las variables.

Definición 4.20 (Árbol de decisión). Modelo, válido tanto para regresión como para clasificación, que predice el valor de una variable dividiendo repetidamente los datos según condiciones sobre las variables de entrada, formando una estructura en forma de árbol. Cada división se elige de modo que separe las observaciones en grupos cada vez más homogéneos respecto a la variable objetivo, según un criterio de impureza (la varianza o el error cuadrático en regresión, y medidas como el índice de Gini o la entropía en clasificación). El espacio de las variables queda así partido en regiones disjuntas $R_1, \dots, R_M$, y la predicción de una observación es la media de la variable objetivo de su región en regresión, o la clase mayoritaria en clasificación. Los árboles capturan de forma natural las relaciones no lineales, aunque un árbol aislado tiende a sobreajustar.

Esta última limitación se supera combinando muchos árboles en lugar de confiar en uno solo.

Definición 4.21 (Métodos de ensamblado). Técnicas que combinan muchos modelos simples, habitualmente árboles de decisión, para obtener un predictor más robusto y preciso que cualquiera de ellos por separado. En el *bagging*, como el *Random Forest*, los árboles se entrenan en paralelo sobre muestras distintas y se promedian. En el *boosting*, como el *gradient boosting*, se añaden de forma secuencial, y cada uno corrige los errores del conjunto anterior. XGBoost es una implementación eficiente y regularizada de esta segunda familia [16].

Con independencia del modelo elegido, estimar su rendimiento real exige evaluarlo sobre datos distintos de los usados para entrenarlo.

Definición 4.22 (Validación cruzada). Procedimiento que divide los datos en K subconjuntos de tamaño similar y entrena el modelo K veces, usando en cada iteración un subconjunto distinto para evaluar y los $K - 1$ restantes para entrenar, de modo que cada observación

se emplea exactamente una vez para evaluar. Si E_k es el error obtenido sobre el k -ésimo subconjunto, la estimación de la capacidad de generalización es su promedio

$$CV = \frac{1}{K} \sum_{k=1}^K E_k,$$

más estable que la de una única partición. La variante más habitual es la validación cruzada de K subconjuntos (K -fold).

La fiabilidad de esa evaluación depende, sin embargo, de que se respete una separación estricta entre lo que el modelo ve y lo que no.

Definición 4.23 (Fuga de información). Situación, también conocida como *data leakage*, en la que el modelo accede durante el entrenamiento a información que no debería estar disponible, lo que produce una estimación excesivamente optimista de su rendimiento y un mal comportamiento real ante datos nuevos. Un caso habitual es que observaciones muy relacionadas queden repartidas entre los conjuntos de entrenamiento y evaluación.

Muchos modelos dependen, además, de ciertos parámetros que no se aprenden a partir de los datos, sino que se fijan de antemano y condicionan su comportamiento, los denominados hiperparámetros. La búsqueda de sus mejores valores se apoya en este mismo esquema de validación.

Definición 4.24 (Optimización de hiperparámetros). Búsqueda de la mejor combinación de hiperparámetros, como la profundidad de un árbol o la intensidad de la regularización. Cada combinación candidata se evalúa mediante validación cruzada, seleccionando la que ofrece mejor rendimiento.

En el aprendizaje no supervisado, junto a las técnicas de reducción de la dimensionalidad y de análisis de dependencia ya descritas, en el trabajo también se emplea un método de agrupamiento y una búsqueda de vecinos.

Definición 4.25 (K-means). Algoritmo de aprendizaje no supervisado que divide un conjunto de observaciones en un número prefijado de grupos K . Cada grupo C_k queda representado por su centro μ_k , y el método busca minimizar la suma de las distancias al cuadrado de cada observación a su centro,

$$\sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2,$$

asignando cada observación al centro más cercano y reajustando los centros de forma iterativa hasta que los grupos se estabilizan.

El K-means exige fijar de antemano el número de grupos, y distintas elecciones producen agrupamientos de calidad desigual. Conviene, por tanto, disponer de una medida objetiva que evalúe la bondad del resultado y ayude a decidir ese número.

Definición 4.26 (Coeficiente de silueta). Medida de la calidad de un agrupamiento que, para cada observación i , compara la distancia media a los elementos de su propio grupo, $a(i)$, con

la distancia media al grupo vecino más próximo, $b(i)$,

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}} \in [-1, 1].$$

Los valores próximos a uno indican observaciones bien asignadas, los cercanos a cero, situadas entre dos grupos, y los negativos, mal asignadas. El promedio sobre todas las observaciones evalúa la validez global del agrupamiento y ayuda a elegir su número [17].

A diferencia del agrupamiento, que reorganiza todo el conjunto en grupos, la última técnica no estructura los datos de forma global, sino que responde a consultas sobre un elemento concreto, recuperando aquellos que más se le parecen.

Definición 4.27 (Búsqueda de vecinos más cercanos (k-NN)). Procedimiento que, dado un elemento de referencia, recupera los k que se encuentran a menor distancia de él en el espacio de características, de donde recibe su nombre (*k-nearest neighbors*, k-NN). La proximidad suele medirse mediante la distancia euclídea, que entre dos vectores $\mathbf{x}$ y $\mathbf{z}$ de dimensión d se define como

$$d(\mathbf{x}, \mathbf{z}) = \sqrt{\sum_{k=1}^d (x_k - z_k)^2}.$$

A diferencia de los algoritmos de clasificación, no predice ninguna etiqueta, sino que ordena los elementos por proximidad para localizar los más parecidos.

El conjunto de técnicas de aprendizaje automático introducidas en esta sección, desde la regresión y la regularización hasta los métodos basados en árboles, la evaluación de modelos y las técnicas no supervisadas, constituye el repertorio habitual del aprendizaje estadístico [18], [19].

4.3 Desarrollo e implementación

En esta sección se detalla la implementación de cada una de las fases que componen la solución, siguiendo el orden en que se ejecutan dentro del *pipeline*, de manera que el resultado de cada etapa sirve de entrada a la siguiente. Se comienza por una visión global que sitúa cada fase dentro del proceso, antes de abordarlas de forma individual.

4.3.1. Arquitectura del pipeline

El proyecto se articula en torno a un *pipeline* de datos que recorre todo el trayecto desde la obtención de la información en bruto hasta su explotación en una plataforma interactiva. La Figura 4.2 resume este flujo a través de las siete fases que lo componen.



Figura 4.2. Visión global del *pipeline* de datos.

El proceso comienza con la ingesta de datos de dos fuentes complementarias: Sofascore, de la que se extraen las estadísticas de rendimiento de cada jugador y Capology, que aporta la información salarial. La cobertura abarca seis ligas europeas a lo largo de las últimas seis temporadas, lo que permite analizar perfiles en contextos competitivos y temporales diversos.

A continuación, los datos pasan por una fase de preprocesamiento e integración en la que se limpian, se normalizan y, sobre todo, se cruzan ambas fuentes para asociar a cada jugador su rendimiento y su salario. Esta integración es uno de los puntos más importantes del proyecto, ya que no existe un identificador común entre fuentes.

Sobre la tabla maestra resultante se desarrolla el análisis exploratorio, que orienta las decisiones de la posterior ingeniería de características. Con el conjunto de datos ya preparado se abordan los componentes analíticos centrales del trabajo: un modelo de regresión, que estima el salario esperado, y un conjunto de técnicas no supervisadas que perfilan a los jugadores mediante un sistema de similitud y la identificación de arquetipos por posición. Finalmente, los resultados se incorporan en una aplicación interactiva, que es la capa de explotación del proyecto y facilita la consulta visual de la información.

4.3.2. Ingesta de datos

La primera fase del *pipeline* corresponde a la ingesta de datos. Pese a su carácter aparentemente instrumental, esta fase influye de manera crucial en el resto del trabajo, ya que la calidad, la cobertura y el nivel de detalle de los datos obtenidos determinan qué análisis serán posibles más adelante y cuáles quedarán fuera de alcance. De ahí la importancia de seleccionar adecuadamente las fuentes y de garantizar que los datos recogidos sean fiables, completos y rastreables hasta su fuente.

En este proyecto, la naturaleza del problema requiere combinar dos tipos de información que no se encuentran disponibles de forma integrada en ningún conjunto de datos público: por un lado, las estadísticas de rendimiento de cada futbolista y, por otro, su remuneración

salarial bruta. Esta información existe, pero se halla dispersa en plataformas especializadas y publicada para su consulta visual, no para su descarga directa. Ante este escenario, la obtención de los datos se ha resuelto mediante técnicas de *web scraping*, cuyos fundamentos se introducen en la Sección 4.2. En la práctica, el *scraping* se ha apoyado en la librería ScraperFC [20], que proporciona acceso a diversas plataformas de datos futbolísticos y que se ha empleado para extraer la información de las dos fuentes seleccionadas. El alcance del análisis abarca seis grandes competiciones europeas a lo largo de seis temporadas, tal como se recoge en la Tabla 4.1.

País	Competición	Identificador en los datos
España	La Liga	spain
Inglaterra	Premier League	england
Italia	Serie A	italy
Alemania	Bundesliga	germany
Francia	Ligue 1	france
Turquía	Süper Lig	turkey

Tabla 4.1. Competiciones analizadas, todas con las temporadas 20/21 a 25/26.

La primera fuente es Sofascore [21], de la cual se obtienen las estadísticas de rendimiento de los jugadores. Para cada combinación de liga y temporada se descargan los totales acumulados de la temporada, lo que da lugar a una tabla amplia de en torno a ciento dieciséis columnas, de las cuales la gran mayoría corresponden a métricas de rendimiento y el resto a identificadores y metadatos. El conjunto de variables cubre las distintas facetas del juego, desde la producción ofensiva hasta las acciones defensivas o las métricas propias de los porteros, tal como se resume en la Tabla 4.2. Cada registro incorpora además los identificadores de jugador y equipo (*player id* y *team id*), que resultarán fundamentales en fases posteriores para agrupar las observaciones de un mismo futbolista a lo largo de distintas temporadas.

Faceta del juego	Variables representativas
Participación	<i>appearances, minutesPlayed, matchesStarted, rating</i>
Producción ofensiva	<i>goals, assists, expectedGoals, expectedAssists, bigChancesCreated</i>
Finalización	<i>totalShots, shotsOnTarget, goalConversionPercentage</i>
Juego de pase	<i>accuratePasses, accuratePassesPercentage, keyPasses, accurateLongBalls</i>
Regate y conducción	<i>successfulDribbles, totalContest, touches, dispossessed</i>
Acciones defensivas	<i>tackles, interceptions, clearances, ballRecovery, blockedShots</i>
Duelos	<i>groundDuelsWon, aerialDuelsWon, totalDuelsWon</i>
Portería	<i>saves, goalsPrevented, cleanSheet, penaltySave</i>
Disciplina	<i>fouls, yellowCards, redCards</i>

Tabla 4.2. Principales categorías de métricas de rendimiento extraídas de Sofascore.

La segunda fuente es Capology [22], que aporta la información salarial. Para cada jugador se obtienen el salario bruto semanal, el salario bruto anual y una versión ajustada del salario, junto con una serie de atributos descriptivos como la posición, la edad, la nacionalidad y el club. Dado que las distintas ligas publican estas cantidades en monedas diferentes (por ejemplo, la Premier League en libras), la descarga se ha realizado forzando la conversión a una moneda común, el euro, lo que garantiza la comparabilidad de los salarios entre competiciones. De entre las variables salariales disponibles, el salario bruto anual constituye la variable objetivo del proyecto. **Conviene señalar que Capology no publica cifras oficiales para todos los jugadores, sino estimaciones, y solo una parte de ellas aparece verificada en la plataforma. Dado que el salario real de un futbolista rara vez es información pública, estas cantidades se han adoptado como la mejor referencia disponible, asumiendo que constituyen una aproximación razonable al salario real y suficientemente consistente para el análisis comparativo que persigue el trabajo.**

Por último, y con el fin de reforzar la trazabilidad y la reproducibilidad del trabajo, la totalidad de las variables ingestadas se documenta de forma detallada en los anexos (Capítulo 8), donde se presenta un diccionario completo con la descripción de cada una de las métricas obtenidas de ambas fuentes. De este modo, cualquier referencia a una variable concreta a lo largo de la memoria puede contrastarse con su definición.

4.3.3. Preprocesamiento e integración

Una vez almacenados los datos en bruto, la segunda fase del *pipeline* los transforma en un conjunto de datos unificado y explotable. Comprende dos tareas distintas: la limpieza técnica de cada fuente por separado y la integración de ambas en una única tabla maestra. Esta segunda tarea es uno de los puntos críticos del proyecto, ya que Sofascore y Capology no comparten ningún identificador común de jugador. El cruce debe apoyarse, por tanto, en la única información compartida: el nombre del jugador y el de su equipo. No es una vía trivial, pues los nombres difieren entre fuentes en grafía, acentuación, nombres intermedios y denominación de los clubes.

La limpieza técnica se ha limitado a lo imprescindible, sin decisiones analíticas (nulos, valores atípicos o selección de variables), que se posponen a fases posteriores. En Sofascore se reduce a renombrar las columnas identificadoras con espacios, corregir el tipo de la variable de temporada (almacenada como número pero usada como identificador) y reordenar las columnas situando primero los identificadores y las métricas clave.

Capology exige algo más de trabajo, ya que la extracción devuelve una estructura irregular, donde la fila de cabecera queda como primer registro y los nombres de columna son genéricos. Se elimina esa fila, se renombran las columnas, se seleccionan los campos comunes a todas las temporadas y se convierten los importes, expresados como texto con formato monetario europeo, a valores numéricos. En ambas fuentes la lógica se ha reunido en una función reutilizable, con comprobaciones automáticas de estructura y tipos, y se ha aplicado de forma uniforme a los treinta y seis ficheros (seis ligas por seis temporadas).

El reto de identificar cuándo dos cadenas de texto se refieren a la misma entidad, pese a diferir en su grafía, es un problema estudiado en el ámbito de la detección de duplicados, para el que se han desarrollado numerosas funciones de similitud entre cadenas [23]. El procedimiento de este trabajo se apoya en esa idea: combina una comparación exacta con una aproximada sobre una clave formada por el nombre del jugador y el de su equipo, estructurada como un emparejamiento en cascada (Figura 4.3) que se aplica de forma independiente a cada liga y temporada. Cada etapa opera solo sobre los casos que la anterior no ha resuelto, ordenadas de la más automática a la más laboriosa.




Figura 4.3. Flujo del emparejamiento en cascada entre Sofascore y Capology.

El proceso parte de una normalización de los nombres que elimina la acentuación, pasa el texto a minúsculas, descarta los caracteres especiales y suprime los espacios sobrantes. Así, dos grafías del mismo jugador que difieren en detalles superficiales pasan a ser idénticas. Esta normalización tiene algunos casos límite conocidos: la letra turca «ı» sin punto se descarta por completo en lugar de convertirse en «i» (lo que afecta a la liga turca) y los guiones se transforman en espacios. Ambos pueden provocar pequeños desajustes, y por eso el proceso incorpora una corrección manual al final.

A continuación se alinean los nombres de los equipos, el segundo componente de la clave. Se identifican de forma automática las discrepancias entre fuentes y se resuelven con una tabla de correspondencias (por ejemplo, «tottenham» con «tottenham hotspur», o «psg» con «paris saint germain»). Incluir el equipo en la clave elimina la ambigüedad de jugadores con nombres parecidos y, además, permite restringir después la búsqueda aproximada al interior de cada plantilla, lo que reduce notablemente el número de comparaciones. Con los equipos ya homogeneizados, un primer cruce exacto sobre el nombre normalizado de jugador y equipo resuelve la mayoría de los emparejamientos.

Los jugadores sin correspondencia exacta pasan a una fase de *fuzzy matching*, apoyada en la función *ratio* de la librería *rapidfuzz* [24]. Esta función cuantifica el parecido entre dos cadenas de texto mediante la distancia de Indel, una variante de la distancia de Damerau-Levenshtein o distancia de edición que solo contempla inserciones y eliminaciones (de modo que una sustitución equivale a una eliminación seguida de una inserción). Dadas dos cadenas a y b de longitudes $|a|$ y $|b|$, y siendo $d_{\text{Indel}}(a, b)$ el número mínimo de tales operaciones necesarias

para transformar una en otra, la similitud normalizada se define como

$$\text{sim}(a, b) = 1 - \frac{d_{\text{Indel}}(a, b)}{|a| + |b|} \in [0, 1].$$

que vale 1 cuando ambas cadenas son idénticas y decrece hacia 0 a medida que difieren. Para cada jugador sin emparejar se busca el candidato con mayor similitud dentro de su mismo equipo y el resultado se clasifica en cuatro niveles de confianza según la puntuación obtenida (Tabla 4.3). La política de aceptación es ligeramente asimétrica, ya que las coincidencias de puntuación muy alta se aceptan de forma automática, y a medida que la similitud baja la intervención manual gana peso, hasta que en los niveles más bajos ninguna se acepta sin confirmación por parte del autor. Se prioriza así la precisión sobre la cobertura, ya que es preferible dejar a un jugador sin salario antes que asignarle uno erróneo.

Nivel	Similitud	Política de aceptación
Automático	$\geq 0,90$	Aceptación directa, sin revisión
Revisión media	$0,75-0,90$	Aceptada salvo falso positivo marcado a mano
Revisión estricta	$0,50-0,75$	Rechazada salvo confirmación manual
Revisión muy estricta	$< 0,50$	Rechazada salvo confirmación manual

Tabla 4.3. Niveles del *fuzzy matching* y su política de aceptación.

Superada la fase automática, se revisan a mano los jugadores que siguen sin salario. Para facilitararlo, se ordenan por equipo y minutos jugados y se contrastan con la plantilla de Capology del equipo correspondiente. Los casos residuales (nombres muy divergentes, apodos o incorporaciones del mercado invernal) se resuelven con una tabla de correspondencias definidas manualmente. Un ejemplo típico es un futbolista registrado con su nombre completo en una fuente y con su apodo en la otra, cuya similitud textual es demasiado baja para resolverse sola.

El resultado es una tabla maestra por cada liga y temporada. Los jugadores sin salario localizado se conservan con ese valor nulo en lugar de descartarse, ya que eliminarlos condicionaría la muestra a la disponibilidad del dato salarial, cuando el filtrado debe responder a criterios deportivos homogéneos y no a la cobertura de una fuente. Por último, las treinta y seis tablas se concatenan en un único conjunto, unificando los metadatos bajo una nomenclatura de liga y temporada que preserva la trazabilidad de cada registro. Sobre este conjunto maestro se llevan a cabo una serie de validaciones finales, como la distribución y la cobertura salarial por liga y temporada, y constituye el punto de entrada común de las fases posteriores.

4.3.4. Análisis exploratorio de datos (EDA)

El análisis exploratorio tiene como objetivo comprender la estructura del conjunto de datos maestro antes del modelado para depurar las inconsistencias de la integración, caracterizar

la variable objetivo y estudiar la relación de las variables con el salario, que es la variable objetivo. Las decisiones que aquí se toman orientan la posterior ingeniería de características.

Diagnóstico y limpieza del conjunto de datos maestro

El punto de partida es el conjunto de datos maestro resultante de la integración, con 20.316 observaciones y 122 columnas, sobre el que se aplica una depuración en varios frentes. En primer lugar se eliminan unos pocos duplicados exactos a nivel de jugador, equipo y temporada, procedentes de la fuente salarial.

Se abordan después los salarios anómalos. Un conjunto de registros presenta salario igual a cero, en su mayoría jugadores cedidos cuya remuneración asume el club de origen y no figura en el club de destino. Como además un valor nulo sería incompatible con la transformación logarítmica prevista, estos ceros se convierten en valores nulos. Un tercer frente son los jugadores con varias filas en una misma temporada por traspasos o cesiones: al tratarse de información real, se conservan íntegros, y su tratamiento se pospone a la ingeniería de características.

El análisis del patrón de valores ausentes (Figura 4.4) distingue dos naturalezas. Por un lado, los nulos estructurales responden a que una métrica no aplica a la posición del jugador, como `goalsPrevented`, propia de porteros y ausente en los jugadores de campo. Por otro lado, los nulos de cobertura reflejan la ausencia del dato por limitaciones de la fuente. Solo los primeros se imputan a cero, tras verificar que el patrón de ausencia coincide con la posición, mientras que los segundos se mantienen como ausentes para no inventar información. Algunas columnas con muchos nulos son en realidad metadatos auxiliares y no variables de análisis, como `download_date`, usada para gestionar los datos de la temporada 25/26 (aún en curso durante el transcurso del proyecto).




Figura 4.4. Columnas con mayor porcentaje de valores nulos.

Las métricas de goles y asistencias esperadas (*expectedGoals* y *expectedAssists*) presentan un caso particular, ya que la fuente solo las publica desde la temporada 2022/23 y faltan por completo en las dos primeras (Figura 4.5). Es una limitación temporal del conjunto de datos, no un error, y plantea una disyuntiva posterior: restringir el modelado a las temporadas con estas métricas, ganando dos variables predictivas a costa de volumen, o conservarlas todas prescindiendo de ellas.




Figura 4.5. Cobertura temporal de las métricas de goles y asistencias esperadas.

La depuración se completa con una optimización de los tipos de datos, que corrige columnas almacenadas como decimales pese a contener enteros. El resultado es un conjunto depurado de 20.307 observaciones con una cobertura salarial global del 90,9 %, que constituye el punto de partida de los análisis siguientes. Esta cobertura se distribuye de forma homogénea entre las seis ligas y las seis temporadas (Tabla 4.4), lo que confirma que la ausencia de salario no se concentra en ninguna competición ni periodo concretos.

Liga	20/21	21/22	22/23	23/24	24/25	25/26
Inglaterra	93,9	92,6	93,5	89,8	93,8	93,7
Francia	87,3	89,7	89,4	89,0	87,5	83,8
Alemania	94,8	95,1	94,9	93,5	97,3	92,5
Italia	93,6	86,2	96,0	93,7	94,0	91,1
España	87,4	88,7	87,0	87,1	87,8	85,3
Turquía	95,2	88,7	92,0	95,3	91,7	82,6

Tabla 4.4. Cobertura salarial (%) por liga y temporada tras la depuración.

Análisis de la variable objetivo

El estudio univariante del salario bruto anual confirma su fuerte asimetría. Los estadísticos descriptivos (Tabla 4.5) muestran una media que casi duplica a la mediana y un percentil 99 que supera en unas quince veces al valor mediano, un patrón de concentración propio de

los mercados de “superestrellas”. Los estadísticos de forma lo cuantifican: en escala lineal la asimetría es extrema y las colas muy pesadas, mientras que al aplicar el logaritmo ambos indicadores se aproximan a los de una normal, en coherencia con la naturaleza log-normal de las variables salariales (Sección 4.2).

Estadístico	Valor (€)
Media	2.193.320
Desviación típica	3.420.934
Mínimo	20.000
Percentil 25	450.000
Mediana (percentil 50)	1.090.000
Percentil 75	2.600.000
Percentil 90	5.190.000
Percentil 99	16.000.000
Máximo	72.000.000

Tabla 4.5. Estadísticos descriptivos del salario bruto anual.

La Tabla 4.6 recoge estos indicadores en ambas escalas. En escala lineal, la asimetría ($\gamma_1 \approx 6$) refleja una cola derecha muy pronunciada y la curtosis ($\gamma_2 \approx 74$) unas colas extraordinariamente pesadas, muy alejadas de la normal. Al aplicar la transformación logarítmica, ambos indicadores se reducen prácticamente a los valores de una distribución normal ($\gamma_1 \approx -0,3$, $\gamma_2 \approx 0,1$), lo que motiva adoptar la transformación logarítmica del salario.

Indicador	Escala lineal	Escala logarítmica
Asimetría (γ_1)	6,038	-0,297
Curtosis (γ_2)	74,266	0,081

Tabla 4.6. Asimetría y curtosis del salario en escala lineal y logarítmica.

La Figura 4.6 muestra el efecto de la transformación. En escala lineal la mayoría de los salarios se concentran en los valores bajos y forman una cola larga que el diagrama de caja marca casi por completo como atípica. En escala logarítmica, en cambio, la distribución se vuelve simétrica y se ajusta bien a la curva normal superpuesta.




Figura 4.6. Distribución del salario bruto anual en escala lineal y logarítmica.

La hipótesis de normalidad sobre el logaritmo del salario se contrasta mediante tests formales, que la rechazan. Conviene matizar el resultado: la potencia de estos contrastes crece con el tamaño muestral [25], de modo que en muestras tan grandes como la de este trabajo llegan a detectar desviaciones mínimas, sin relevancia práctica. La conclusión se apoya, por tanto, en el conjunto de la evidencia gráfica y descriptiva. Los gráficos cuantil-cuantil (Figura 4.7) lo resumen. En escala lineal los puntos se separan de la referencia en ambas colas, mientras que sobre el logaritmo se alinean en la zona central. **El logaritmo del salario, sin ser exactamente normal, es lo bastante próximo para el modelado de regresión, donde la normalidad exigible es la de los residuos, no la de la variable en sí.**




Figura 4.7. Gráfico cuantil-cuantil del salario en escala lineal y logarítmica frente a la distribución normal.

Esto tiene una consecuencia sobre la detección de valores atípicos. Sobre el salario en es-

cala lineal, el criterio del rango intercuartílico (Sección 4.2) marca como atípica una fracción elevada de la muestra que no es sino la cola natural de la distribución; sobre el logaritmo, la proporción se reduce y recoge desviaciones genuinas. Se adopta por tanto el logaritmo como escala de referencia, y los salarios más altos no se tratan como ruido, sino como parte estructural del fenómeno.

El análisis comparativo revela una marcada jerarquía salarial entre ligas (Figura 4.8): la Premier League encabeza la mediana, seguida de La Liga y la Serie A, con la Süper Lig en la parte baja, en coherencia con la dimensión económica de cada competición. La liga se perfila así como una variable contextual destacable.




Figura 4.8. Distribución del logaritmo del salario por liga.

En el eje temporal se observa un crecimiento sostenido de la media y mediana salarial a lo largo de las seis temporadas (Figura 4.9). Este efecto de inflación implica que un modelo entrenado con temporadas antiguas tendería a infraestimar los salarios más recientes. La forma de neutralizarlo, que sería incorporar la temporada como variable o deflactar los salarios, se decide en la fase siguiente. El detalle por liga y temporada (Figura 4.10) confirma que la tendencia es común a las seis competiciones, sobre las que se superpone la jerarquía ya descrita.




Figura 4.9. Evolución de la media y la mediana salarial por temporada y crecimiento acumulado de la mediana.




Figura 4.10. Mediana salarial por liga y temporada.

Análisis de las variables contextuales

El estudio de las variables categóricas aporta el contexto para interpretar la relación entre rendimiento y salario. La *posición* distingue cuatro categorías (portero, defensa, centrocampista y delantero), con una distribución acorde a la composición habitual de las plantillas (Figura 4.11). Su relación con el salario (Figura 4.12) sitúa a los porteros como la posición peor remunerada en mediana y a delanteros y centrocampistas en la parte alta, lo que sugiere una prima a las funciones ofensivas. Además, las métricas útiles para explicar el salario difieren según la posición, lo que podría motivar a considerar modelos segmentados en la fase de modelado.




Figura 4.11. Distribución de jugadores por posición.






Figura 4.12. Distribución del logaritmo del salario por posición.

La *edad*, aun siendo numérica, presenta un efecto marcadamente no lineal sobre el salario. Su distribución (Figura 4.13) está truncada a la izquierda por la edad de profesionalización, con mediana en veintiséis años. La curva que relaciona edad y salario (Figura 4.14) reproduce el perfil de ciclo laboral característico, con una fase inicial de crecimiento hasta la madurez deportiva, un máximo sostenido en la veintena larga y un ligero declive posterior. El cruce de edad y posición (Figuras 4.15 y 4.16) apunta a que estas trayectorias no son del todo uniformes entre posiciones, lo que sugiere tener en cuenta la posición en el modelado, ya sea segmentando los modelos o incorporándola como una variable más, una cuestión que se examina en la fase correspondiente (*feature engineering*).




Figura 4.13. Distribución de edades en el conjunto de datos.




Figura 4.14. Curva edad-salario: mediana del salario por edad.




Figura 4.15. Curvas edad-salario por posición.




Figura 4.16. Mediana del logaritmo del salario por posición y grupo de edad.

Por último, la *nacionalidad* es una variable de alta cardinalidad, con 131 categorías. Su distribución (Figura 4.17) revela dos rasgos. Las seis nacionalidades más frecuentes coinciden

con los seis países de las ligas estudiadas, reflejo del predominio de jugadores locales, y la variable está muy concentrada, ya que las diez principales reúnen cerca de dos tercios de las observaciones. En relación con el salario (Figura 4.18), el orden resultante es solo aparentemente paradójico. Encabezan la mediana Inglaterra y una serie de nacionalidades cuyos jugadores solo llegan a estas ligas si destacan lo suficiente para ser fichados, mientras que países muy representados quedan por debajo al incluir su muestra a toda la población local, con muchos salarios modestos. Más que la calidad del jugador, la nacionalidad refleja así la liga en la que juega, una razón por la que más adelante se descartará como variable predictora (Sección 4.3.5).




Figura 4.17. Nacionalidades más frecuentes en el conjunto de datos.




Figura 4.18. Salario mediano por nacionalidad restringido a las de mayor representación en la muestra.

A lo largo de este análisis se emplea la mediana como medida de tendencia central, en lugar de la media, por su robustez frente a la fuerte asimetría de la distribución salarial. El

estudio de las variables contextuales se completa a continuación con el de las estadísticas de rendimiento y su relación con el salario.

Estructura de las variables de rendimiento

El conjunto reúne alrededor de 110 estadísticas de rendimiento por jugador, lo que plantea cuánta información realmente independiente contienen. Su estudio persigue un doble objetivo. Por un lado, detectar redundancias entre variables, algo determinante para el sistema de similitud. Por otro, comprender la estructura latente del conjunto de cara a la selección de variables en la regresión.

Un primer examen de la variabilidad, mediante la varianza relativa de cada variable, muestra que ninguna carece de recorrido. Las de menor variabilidad son el `rating` (varianza relativa 0,019, con valores entre 6 y 8) y el `accuratePassesPercentage` (0,029, entre el 70 % y el 90 %), métricas que se concentran en rangos estrechos, algo esperable entre profesionales. Ninguna se descarta por este motivo en esta fase, ya que conservan valor discriminativo.

El análisis de la correlación de Pearson (Sección 4.2) revela una redundancia considerable en el conjunto (Figura 4.19). Un número elevado de pares alcanza correlaciones muy altas (Tabla 4.7) y algunos resultan casi idénticos, como los pases clave (`keyPasses`) y los que terminan en un remate del compañero (`totalAttemptAssist`), que miden esencialmente lo mismo. Esta redundancia afecta de lleno al sistema de similitud, donde conservar variables equivalentes pondera dos veces la misma información y sesga el cálculo de distancias.

Umbral de correlación	N.º de pares
$ r \geq 0,99$	10
$ r \geq 0,95$	27
$ r \geq 0,90$	67
$ r \geq 0,80$	199
$ r \geq 0,70$	454

Tabla 4.7. Número de pares de variables de rendimiento por umbral de correlación absoluta.




Figura 4.19. Matriz de correlación entre las variables de rendimiento.

Para organizar esa redundancia en grupos con sentido, se aplica un agrupamiento jerárquico (Sección 4.2) a partir de la correlación entre variables. El dendrograma resultante (Figura 4.20) reúne las variables en bloques que reproducen las distintas facetas del juego. Los cinco principales, recogidos en la Tabla 4.8, concentran la mayor parte de las variables y agrupan el volumen de juego y el pase, la creación ofensiva, la finalización, la portería y los duelos, mientras que un conjunto de métricas muy específicas queda aislado en bloques pequeños. Lo llamativo es que el método llega a estos grupos por sí solo, únicamente a partir del comportamiento numérico de las variables y sin ningún conocimiento previo del fútbol, lo que respalda su coherencia y sugiere conservar una variable representativa de cada bloque.




Figura 4.20. Dendrograma del agrupamiento jerárquico de las variables de rendimiento según su correlación.

Bloque temático	N.º vars.	Variables representativas
Volumen / pase posicional	23	minutesPlayed, appearances, totalPasses, accuratePasses, touches
Creación ofensiva	13	keyPasses, expectedAssists, assists, bigChancesCreated, totalCross
Finalización	11	goals, expectedGoals, totalShots, shotsOnTarget, bigChancesMissed
Portería	11	saves, savesParried, savedShotsFromInsideTheBox, goalKicks, penaltySave
Duelos / defensa de contacto	9	tackles, tacklesWon, duellLost, fouls, wasFouled

Tabla 4.8. Principales bloques temáticos de variables identificados por el agrupamiento jerárquico.

Por último, un análisis de componentes principales (Sección 4.2) permite cuantificar esa redundancia. La curva de varianza acumulada (Figura 4.21) confirma que la información real del conjunto se concentra en muchas menos dimensiones de las que sugiere su número de variables. De hecho, alrededor de una quinta parte de los componentes basta para retener el 80 % de la varianza, y con aproximadamente un tercio se alcanza el 90 %. Este resultado orienta el tratamiento posterior de cada modelo. La regresión, al apoyarse en modelos poco sensibles a la multicolinealidad, puede prescindir de la reducción. En cambio, el sistema de similitud se beneficia de trabajar con menos dimensiones, de forma que las distancias entre jugadores no queden dominadas por los bloques de variables más repetidos.




Figura 4.21. Varianza explicada por componente y varianza acumulada del análisis de componentes principales sobre las variables de rendimiento.

Relación entre el rendimiento y el salario

El último paso conecta las estadísticas de rendimiento con la variable objetivo, tomando siempre el logaritmo del salario conforme a lo establecido antes. El estudio de la correlación deja un mensaje claro. Ninguna variable individual supera una correlación en torno a 0,40, de modo que el salario no se explica por una sola métrica, sino por la combinación de muchas. Las mejor correlacionadas son las de volumen y exposición, como los pases, los toques o los minutos, lo que indica que el primer factor asociado a un salario alto es participar mucho. El contraste entre las correlaciones de Pearson y de Spearman (Sección 4.2) es muy pequeño, lo que confirma que, tras la transformación logarítmica, las relaciones son aproximadamente lineales.

Al observar los datos por posición aparece un matiz relevante. Las variables más asociadas al salario no son las mismas para cada puesto (Tabla 4.9), de modo que un análisis puramente global pasa por alto estas diferencias. En los porteros pesan la titularidad y las porterías a cero, en los defensas y centrocampistas el pase en campo rival y la organización, y en los delanteros las métricas de remate y gol. Esta observación sugiere que la posición es un factor a tener en cuenta en el modelado, cuya forma concreta de incorporarse se estudia en la fase correspondiente.

Portero	Defensa	Centrocampista	Delantero
<i>accurateOwnHalfPasses</i>	<i>accurateOppositionHalfPasses</i>	<i>accurateFinalThirdPasses</i>	<i>shotsFromInsideTheBox</i>
<i>cleanSheet</i>	<i>rating</i>	<i>accurateOppositionHalfPasses</i>	<i>goalsAssistsSum</i>
<i>accuratePasses</i>	<i>accuratePasses</i>	<i>rating</i>	<i>expectedGoals</i>
<i>matchesStarted</i>	<i>accurateFinalThirdPasses</i>	<i>totalOppositionHalfPasses</i>	<i>totalShots</i>
<i>minutesPlayed</i>	<i>totalPasses</i>	<i>accuratePasses</i>	<i>shotsOnTarget</i>

Tabla 4.9. Variables de rendimiento más correlacionadas con el logaritmo del salario en cada posición.

Durante esta inspección se detectó además una anomalía en la variable *goalsPrevented*, métrica exclusiva de porteros que presentaba valores no nulos en jugadores de campo. Correspondían al valor del portero del equipo, replicado erróneamente sobre el resto de la plantilla

durante la extracción, un sesgo de la fuente circunscrito a una única liga y temporada que llegaba a inducir una correlación espuria con el salario. La anomalía se corrige en la ingeniería de características forzando la ausencia del valor para todo jugador que no sea portero.

Un análisis final mediante información mutua (Sección 4.2), capaz de captar relaciones no monótonas, confirma el mismo conjunto de variables relevantes y anticipa que el problema se prestará mejor a modelos no lineales que a una regresión lineal simple.

Con ello se cierra el análisis exploratorio. Las decisiones acumuladas (escala logarítmica del salario, consideración de la posición, reducción de redundancia, preferencia por modelos no lineales y corrección de los sesgos detectados) constituyen el punto de partida de la ingeniería de características.

4.3.5. Feature engineering

Una vez comprendida la estructura de los datos, la fase de ingeniería de características transforma el conjunto maestro en los datos concretos que alimentan cada modelo. Esta fase parte de una limpieza y un filtrado comunes, y a continuación se bifurca en dos preparaciones distintas, ya que el modelo de regresión y el sistema de similitud tienen necesidades diferentes.

Limpieza y filtrado comunes

Sobre el conjunto maestro se aplican primero las decisiones acumuladas durante el análisis exploratorio, que dan lugar a una base común para las dos ramas posteriores. En primer lugar se corrige la anomalía de *goalsPrevented* descrita en el apartado anterior, dejando la variable como exclusiva de porteros. Después se descartan los jugadores sin posición asignada, en su mayoría futbolistas con muy pocos minutos a los que la fuente no atribuye una posición principal, y cuya presencia impediría cualquier tratamiento diferenciado por puesto.

El paso de mayor impacto es el filtro de participación mínima. Las estadísticas de un jugador con muy pocos minutos son extremadamente ruidosas, ya que un delantero que anota en una racha breve puede exhibir cifras que no representan su nivel real. Para evitar modelar ese ruido se conservan únicamente los jugadores con al menos 450 minutos disputados, equivalentes a cinco partidos completos. La Figura 4.22 muestra cómo una parte importante de las observaciones se concentra en muy pocos minutos, que son precisamente las que el filtro elimina.




Figura 4.22. Distribución de los minutos disputados por temporada.

Este filtrado tiene un efecto secundario muy favorable. La cobertura salarial, en torno al 91 % en el conjunto de partida, asciende a prácticamente el 100 % tras el filtro (Tabla 4.10), ya que los jugadores sin salario eran en su mayoría canteranos y cedidos con poca participación, justo los que quedan fuera. El filtro no solo reduce el ruido, sino que mejora la calidad global de los datos. Por último, para los jugadores con varias entradas en una misma temporada, fruto de traspasos, se conserva la correspondiente al equipo en el que disputaron más minutos, de modo que cada jugador queda representado una sola vez por temporada. El resultado es un conjunto filtrado de 14.202 observaciones que sirve de entrada común a las dos ramas siguientes.

Liga	20/21	21/22	22/23	23/24	24/25	25/26
Inglaterra	100,0	100,0	100,0	100,0	99,5	100,0
Francia	100,0	100,0	100,0	100,0	99,7	100,0
Alemania	100,0	100,0	99,7	100,0	100,0	100,0
Italia	100,0	97,2	100,0	99,8	100,0	100,0
España	100,0	100,0	99,8	100,0	100,0	99,8
Turquía	100,0	100,0	100,0	100,0	99,7	100,0

Tabla 4.10. Cobertura salarial (%) por liga y temporada tras el filtrado.

Datos para el modelo de regresión

A partir de la base común se construye el conjunto para la regresión salarial, cuyo objetivo es estimar el salario de cada jugador. La variable objetivo es el logaritmo del salario bruto anual. Esta transformación, ya justificada en el análisis exploratorio, no solo aproxima la distribución a la normal, relevante para los modelos lineales de referencia, sino que además hace que los errores se penalicen en términos relativos y no absolutos, algo importante dado el enorme rango salarial, y que los residuos, base de la posterior detección de desajustes, resulten comparables entre jugadores de muy distinto nivel salarial.

Las estadísticas de rendimiento se normalizan por noventa minutos (Sección 4.2) para que reflejen el rendimiento por unidad de tiempo y no el simple volumen acumulado, que depende de cuánto juega cada futbolista. Sobre ese conjunto se reduce la redundancia detectada en el análisis exploratorio, eliminando las variables que aportaban información casi idéntica a otras y conservando una representación de cada faceta del juego. Como el modelo previsto se basa en árboles de decisión, tolerante a la correlación entre variables, la selección mantiene un núcleo informativo amplio en lugar de una reducción agresiva.

Las variables categóricas (la posición, la liga y la temporada) se transforman mediante codificación *one-hot* (Sección 4.2), omitiendo en cada una una categoría de referencia para evitar dependencias lineales entre las columnas resultantes. Aunque los modelos basados en árboles no requieren esta codificación, se aplica porque en esta fase todavía no se había determinado qué modelo ofrecería mejor precisión, y las alternativas lineales evaluadas) sí la necesitan, de modo que se adopta una representación común válida para todas las familias comparadas.

Un último aspecto son los valores ausentes de origen estructural, como los de las métricas de goles y asistencias esperadas en las temporadas en que la fuente todavía no las publicaba. En lugar de descartar estas variables, muy relevantes en la analítica actual, se imputan a cero y se acompañan de una variable indicadora que señala si el dato estaba disponible, lo que permite al modelo distinguir una ausencia real de un valor nulo genuino.

Datos para los análisis no supervisados

La segunda rama persigue objetivos distintos de la regresión y da lugar a una preparación propia, compartida por los dos usos no supervisados del trabajo, la búsqueda de jugadores similares y la identificación de arquetipos por posición. En ambos casos interesa el estilo de juego del futbolista y no su contexto, por lo que se excluyen de las variables las de liga, temporada y nacionalidad. Así, dos futbolistas con un estilo equivalente resultan comparables aunque jueguen en competiciones o épocas distintas. Tampoco se filtra por salario, ya que el conjunto de jugadores de interés incluye también a quienes no tienen ficha salarial registrada.

Dado que las estadísticas que definen a un portero y a un jugador de campo son radicalmente distintas, se construyen dos conjuntos independientes, uno para cada grupo, cada uno con las variables propias de su rol. Sobre ellos se aplican de nuevo la normalización por noventa minutos y, a continuación, una estandarización robusta (Sección 4.2), necesaria para que todas las variables pesen por igual en los cálculos posteriores y basada en la mediana y el rango intercuartílico por su resistencia a los valores extremos.

Finalmente, se reduce la dimensionalidad de cada conjunto mediante un análisis de componentes principales (Sección 4.2). Un número elevado de variables perjudica tanto el cálculo de distancias como la formación de grupos, pues en espacios de alta dimensión las diferencias entre jugadores tienden a diluirse. Se retiene el número de componentes que explica en torno al 85 % de la varianza (Figura 4.23), lo que resume el perfil de cada jugador en un vector compacto. La curva de varianza acumulada alcanza ese umbral, marcado en la figura, en torno a la componente 17 para los jugadores de campo, de las 52 variables de partida, y a la

componente 13 para los porteros, con un espacio más reducido de 24 variables, que recogen cerca del 88 % de la varianza. Cada jugador queda así representado por sus componentes principales, junto con una serie de metadatos (edad, posición, salario) que no intervienen en los cálculos pero permiten filtrar después las consultas.




Figura 4.23. Varianza explicada acumulada del análisis de componentes principales para jugadores de campo y porteros.

Esta representación reducida constituye la base común de los dos análisis no supervisados que se desarrollan en la fase de modelado. Por un lado, permite medir la proximidad entre jugadores para localizar perfiles parecidos. Por otro, sirve de punto de partida para agrupar a los futbolistas en arquetipos según su estilo. Ya en esta etapa puede comprobarse de forma cualitativa que el espacio construido captura bien el estilo de juego. Al buscar los jugadores más próximos a algunos futbolistas conocidos, los resultados resultan coherentes con el criterio futbolístico (Tabla 4.11), lo que respalda la validez de la representación obtenida.

Jugador de referencia	Perfiles más próximos
Vinicius Júnior	Khvicha Kvaratskhelia, Rafael Leão, Matheus Cunha
Robert Lewandowski	Ermedin Demirović, Joselu, Odsonne Édouard
Virgil van Dijk	Jonny Evans, Willi Orbán, Nayef Aguerd . . .

Tabla 4.11. Ejemplos de jugadores más próximos en el espacio de similitud.

4.3.6. Modelado y evaluación

Sobre los conjuntos preparados en la fase anterior se construyen los tres componentes analíticos del trabajo. El primero es un modelo de regresión que estima el salario de cada jugador y permite detectar desajustes entre lo que cobra y lo que su rendimiento sugiere. Los otros dos son de naturaleza no supervisada, un sistema que recomienda jugadores de perfil parecido y un análisis que agrupa a los futbolistas en arquetipos de estilo.

Modelo de regresión salarial

El objetivo de esta parte es estimar el salario de un jugador a partir de su rendimiento, de modo que la diferencia entre el salario real y el estimado sirva para identificar futbolistas mejor o peor pagados de lo que su juego justificaría. La variable objetivo es el logaritmo del salario, según lo establecido en el análisis exploratorio.

El primer requisito es obtener una estimación realista del rendimiento del modelo. Como un mismo jugador aparece en varias temporadas con estadísticas parecidas, repartir esas observaciones entre entrenamiento y evaluación provocaría una fuga de información (Sección 4.2) que inflaría artificialmente los resultados. Para evitarlo, todas las particiones se realizan por jugador, de forma que las temporadas de un mismo futbolista caen siempre juntas y nunca se evalúa sobre alguien ya visto en el entrenamiento. Se reserva así un 20 % de los jugadores como conjunto de prueba, que no interviene hasta la evaluación final, y el ajuste se realiza sobre el resto mediante validación cruzada (Sección 4.2) agrupada también por jugador.

Con este esquema se comparan primero cuatro familias de modelos, dos lineales (*Ridge* y *Lasso*) y dos basados en árboles (*Random Forest* y *XGBoost*). Los resultados iniciales son parecidos entre sí, en torno a un R^2 de 0,57, por lo que a continuación se optimizan los hiperparámetros (Sección 4.2) **del modelo con más potencial, XGBoost**, mediante la biblioteca Optuna [26], con lo que se confirma como la mejor opción. También se comprueba en este punto una cuestión que quedó abierta en el análisis exploratorio, si conviene entrenar un modelo distinto por posición. **La prueba muestra que segmentar no mejora al modelo único que incluye la posición como una variable más, ya que al dividir los datos cada modelo pierde los patrones comunes entre posiciones. Se adopta, por tanto, un modelo global.**

Hasta aquí el modelo emplea solo variables de rendimiento y alcanza un R^2 cercano a 0,60. El salto de calidad llega al incorporar la trayectoria salarial del jugador, a través de dos variables, el salario de la temporada anterior y la tendencia de su evolución reciente. El problema es que no todos los jugadores tienen un año previo en los datos, como los debutantes o los recién llegados de ligas no cubiertas. Para aprovechar esa información sin dejar a nadie sin estimación, se adopta un esquema de dos modelos, uno que usa el histórico salarial para quienes lo tienen y otro que recurre solo al rendimiento para el resto. Cada jugador se predice con el que le corresponde, y la combinación de ambos constituye el modelo definitivo.

Evaluable sobre el conjunto de prueba reservado, el modelo combinado alcanza un R^2 de 0,72 (Tabla 4.12), frente al 0,59 del modelo basado solo en rendimiento. La mejora procede de los jugadores con histórico, para los que la predicción es muy precisa, mientras que quienes carecen de él mantienen un techo más bajo por ser intrínsecamente más difíciles de estimar al no tener trayectoria observable.

Modelo	R^2	MAE	RMSE
Combinado (con histórico)	0,72	0,45	0,64
Solo rendimiento (XGBoost)	0,59	0,61	0,78
Referencia lineal (Ridge)	0,56	0,62	0,80

Tabla 4.12. Rendimiento de los modelos sobre el conjunto de prueba.

El análisis de la importancia de las variables (Figura 4.24, izquierda) confirma que el salario de la temporada anterior es, con diferencia, el predictor más influyente, lo que refleja la fuerte inercia del mercado salarial. A cierta distancia le sigue la liga, encabezada por la Premier League, y a continuación un conjunto de métricas de rendimiento, como los pases en el último tercio, las métricas de goles y asistencias esperadas, los goles encajados o el *rating*, mientras que la tendencia salarial reciente aporta un peso más modesto. El modelo lineal de referencia (Ridge, derecha) ofrece una lectura complementaria del signo de los efectos, en la que las ligas vuelven a ser el factor dominante, de nuevo con la Premier League a la cabeza, seguida de la Bundesliga, la Serie A y La Liga, y en la que la edad aparece como uno de los coeficientes positivos más destacados. Conviene señalar que el peso del histórico matiza la naturaleza del modelo, que recoge tanto el rendimiento del jugador como la inercia de su salario previo.




Figura 4.24. Importancia de las variables en el modelo con histórico (izquierda) y coeficientes del modelo lineal de referencia (derecha).

El resultado principal de esta parte es el residuo del modelo, es decir, la diferencia entre lo que un jugador cobra y lo que el modelo estima que debería cobrar. Cuando esa diferencia es positiva, el jugador cobra más de lo que su rendimiento sugiere y se señala como posible sobrepagado. Cuando es negativa, cobra menos y se señala como posible infrapagado. Para que la comparación sea fiable, el salario estimado de cada jugador se obtiene mediante validación cruzada, es decir, con un modelo que nunca lo ha visto durante el entrenamiento.

El análisis de los casos extremos resulta muy coherente con el conocimiento futbolístico (Tabla 4.13). Entre los infravalorados aparecen jóvenes talentos aún con fichas bajas en grandes

clubes, así como casos singulares como el de Santi Cazorla, que regresó al club de su ciudad para retirarse y se ofreció a percibir el salario mínimo, muy por debajo de lo que su rendimiento sugeriría. Entre los sobrevalorados figuran estrellas consagradas y jóvenes de gran proyección ya con contratos elevados, como Nico Williams, Jan Oblak o Lamine Yamal, cuyos salarios responden a factores que el modelo no observa, como la reputación, el valor de mercado o las expectativas de futuro. A ellos se suma algún caso de naturaleza distinta, como el de N'Golo Kanté, cuyo elevado salario en el Fenerbahçe se explica por la tendencia de algunas ligas, como la turca o las de Oriente Medio, a ofrecer fichas muy altas a jugadores de gran experiencia que recalcan en ellas para cerrar su carrera. En estos casos, un residuo elevado no es un error del modelo, sino la señal de que el salario responde a algo más que al rendimiento de una temporada.

Jugador	Pos.	Equipo	Real	Estimado
<i>Infrapagados (cobran menos de lo estimado)</i>				
Lyle Foster	F	Burnley	0,05	3,51
Hannibal Mejbri	F	Burnley	0,03	1,86
Yan Diomande	F	RB Leipzig	0,75	5,96
Jacobo Ramón	D	Como	0,30	2,62
Santi Cazorla	M	Real Oviedo	0,19	1,51
<i>Sobrepagados (cobran más de lo estimado)</i>				
Omar Marmoush	F	Manchester City	17,77	3,30
Franco Mastantuono	F	Real Madrid	7,29	1,13
N'Golo Kanté	M	Fenerbahçe	6,88	1,01
Jorrel Hato	D	Chelsea	7,23	0,90
Kerem Aktürkoğlu	F	Fenerbahçe	5,94	0,96

Tabla 4.13. Ejemplos de jugadores con mayor desajuste salarial en la temporada 25/26 (salarios en millones de euros).

Sistema de similitud entre jugadores

El sistema de similitud es la funcionalidad central de la plataforma. Dado un jugador, localiza a los más parecidos por su estilo de juego y los presenta junto a su salario y el ahorro que supondrían, lo que permite buscar alternativas de perfil equivalente y menor coste. Para ello utiliza la representación reducida de cada jugador obtenida en la fase anterior, que resume su estilo de juego en un conjunto de componentes, y mide el parecido entre dos jugadores como la distancia que los separa en esa representación. Porteros y jugadores de campo se tratan por separado, ya que sus estadísticas no son comparables.

Conviene precisar en qué consiste técnicamente. El sistema realiza una búsqueda de vecinos más cercanos (Sección 4.2), es decir, recupera los jugadores más próximos a uno dado, sin predecir ninguna etiqueta ni agrupar el conjunto. La parte que realmente aprende de los datos es el análisis de componentes principales de la fase anterior, que resume el estilo de cada jugador en unas pocas variables sobre las que después se mide la cercanía. Los candidatos se restringen a los jugadores activos en la última temporada y a la misma posición que el de referencia, y pueden filtrarse además por edad, liga o salario inferior, orientando la búsqueda a reemplazos viables.

La Tabla 4.14 ilustra una consulta real. Para Vinicius Júnior, con un salario de 25 M€, el sistema propone alternativas de estilo similar restringidas a jugadores más baratos, mostrando en cada caso el ahorro potencial respecto a su ficha. El resultado combina nombres de primer nivel, como Kvaratskhelia, con jóvenes promesas de coste muy inferior, que es precisamente el tipo de recomendación de valor para una labor de *scouting*.

Jugador	Equipo	Edad	Salario	Ahorro
Kenan Yildiz	Juventus	20	3,0	22,0
Dani Olmo	FC Barcelona	27	12,5	12,5
Khvicha Kvaratskhelia	Paris Saint-Germain	24	16,4	8,6
Fermín López	FC Barcelona	22	7,3	17,7
Bradley Barcola	Paris Saint-Germain	23	7,3	17,7

Tabla 4.14. Reemplazos de perfil similar a Vinicius Júnior (ahorro en M€).

La validez del sistema se comprueba de forma cualitativa, contrastando que sus recomendaciones tengan sentido futbolístico (Tabla 4.15). Los resultados son coherentes, los delanteros rematadores se emparejan entre sí, los centrocampistas organizadores también, y así en cada perfil, lo que confirma que el espacio construido captura el estilo de juego y no simple ruido estadístico.

Jugador de referencia	Jugadores más próximos
Robert Lewandowski	Odsonne Édouard, Nicolas Jackson, Victor Osimhen
Pedri	Luka Modrić, Nicolò Barella, Manuel Locatelli
Rodri	Manuel Locatelli, Eduardo Camavinga, Granit Xhaka
Jan Oblak	Mile Svilar, Ederson, Thibaut Courtois

Tabla 4.15. Ejemplos de jugadores más próximos en el espacio de estilo para algunos futbolistas de referencia.

Esta cercanía puede además representarse gráficamente proyectando esa representación sobre sus dos primeras componentes (Figura 4.25). En el ejemplo, tomando a Pedri como referencia, sus perfiles más próximos, mediocampistas de corte creativo como Vitinha, Luka Modrić, Nicolò Barella, Manuel Locatelli o Nicolò Fagioli, se sitúan a su alrededor, mientras que el resto de jugadores de su posición se dispersan por el gráfico.




Figura 4.25. Proyección del espacio de estilo sobre sus dos primeras componentes, con un jugador de referencia y sus perfiles más próximos.

Arquetipos de jugador

El tercer componente aborda una pregunta distinta de la anterior. En lugar de buscar parecidos a un jugador concreto, trata de descubrir qué tipos de futbolista existen dentro de cada posición. Para ello se aplica un agrupamiento con el algoritmo K-means (Sección 4.2) sobre los mismos vectores de estilo, de forma independiente para defensas, centrocampistas y delanteros. El agrupamiento se hace por posición y no sobre el conjunto completo, ya que un agrupamiento global se limitaría a reproducir la posición, que es una división ya conocida.

El número de grupos por posición se decide mediante un análisis del coeficiente de silueta (Sección 4.2), examinando no solo su valor medio sino la calidad de cada grupo por separado, como ilustra la Figura 4.26 para el caso de los delanteros. Este análisis revela que separar en tres grupos introduce siempre uno de baja calidad, con muchos jugadores mal asignados, mientras que dos grupos producen agrupaciones limpias y equilibradas. Se adoptan, por tanto, dos arquetipos por posición, que resultan claramente interpretables en términos futbolísticos (Tabla 4.16).




Figura 4.26. Coeficiente de silueta por número de grupos para los delanteros.

Posición	Arquetipo	Salario medio
Defensa	Central de área	2,42 M€
	Defensa lateral	1,89 M€
Centrocampista	Medio creativo	4,47 M€
	Medio de contención	1,77 M€
Delantero	Rematador de área	2,98 M€
	Atacante asociativo	2,86 M€

Tabla 4.16. Arquetipos identificados por posición y salario medio de cada uno.

Los perfiles obtenidos se corresponden con figuras reconocibles del fútbol actual, como el central de área frente al lateral, el medio creativo frente al de contención, o el rematador de área frente al atacante asociativo que participa más en la elaboración. Al asignar jugadores concretos a sus arquetipos, el resultado es intuitivo, con Lewandowski como rematador de área, Vinicius como atacante asociativo o Rodri y Pedri como medios creativos. La proyección del conjunto sobre un mapa bidimensional (Figura 4.27) muestra además cómo los arquetipos ocupan regiones diferenciadas del espacio de estilo.




Figura 4.27. Proyección bidimensional de los jugadores de campo, coloreados por posición y por arquetipo.

El análisis del salario medio de cada arquetipo revela un patrón coherente con lo observado a lo largo del trabajo, ya que los perfiles más creativos y ofensivos concentran los salarios más altos dentro de su posición, como el medio creativo frente al de contención. Ello confirma una vez más que el mercado premia la producción y la creación de juego.

Con estos tres componentes concluye la fase de modelado. En conjunto, el trabajo integra un modelo supervisado de regresión y tres técnicas no supervisadas con propósitos complementarios, la reducción de la dimensionalidad para representar el estilo, la búsqueda de vecinos para recomendar y el agrupamiento para tipificar. Sus resultados alimentan la plataforma interactiva que se describe a continuación.

4.3.7. **Despliegue: plataforma interactiva**

La última fase del *pipeline* convierte los modelos y los conjuntos de datos elaborados en una herramienta consultable y explorable. Sin esta capa, los resultados quedarían restringidos a los cuadernos de trabajo y solo serían accesibles para quien pudiera ejecutarlos. La plataforma persigue, por tanto, que cualquier persona interesada en el análisis, sin conocimientos de programación, pueda explorar los datos y las estimaciones del modelo.

La aplicación se ha desarrollado con Streamlit [27], una biblioteca de Python que permite construir aplicaciones web interactivas de análisis de datos escribiendo únicamente código Python, sin necesidad de tecnologías web específicas. Esta elección responde a la naturaleza del proyecto, ya que permite reutilizar directamente los artefactos generados en las fases anteriores y traducir cada resultado en un elemento visual sin salir del mismo entorno de trabajo. El despliegue se ha realizado en Streamlit Community Cloud, un servicio gratuito que publica la aplicación a partir del repositorio de GitHub del proyecto, de modo que cada cambio subido al repositorio actualiza de forma automática la versión en producción. La plataforma es accesible de forma pública en la dirección <https://tfm-futbolistas.streamlit.app/>.

La aplicación se estructura en cinco secciones, accesibles desde un menú lateral, que recogen las distintas funcionalidades del trabajo.

El *Buscador de reemplazos* constituye la funcionalidad central y da forma al sistema de similitud. El usuario selecciona un jugador de referencia, acotando la búsqueda por posición, liga o equipo, y la aplicación devuelve los futbolistas de perfil más parecido de la última temporada. La consulta puede refinarse mediante filtros que restringen los candidatos a jugadores más baratos, dentro de un rango de edad o de ligas concretas. Los resultados se presentan junto al salario de cada candidato y el ahorro que supondría respecto al jugador de referencia, lo que traduce la similitud estadística en una recomendación de valor práctico.

La sección *Jugador* presenta la ficha individual de cada futbolista. Reúne sus datos básicos, el arquetipo al que pertenece y su perfil de rendimiento, representado mediante un diagrama de radar que sitúa al jugador en percentiles respecto al resto de futbolistas de su misma posición. La ficha incorpora además la valoración salarial del modelo de regresión, mostrando el salario real junto al estimado y la diferencia entre ambos, que señala si el jugador cobra por encima o por debajo de lo que su rendimiento predice.

Las secciones *Ligas* y *Clubes* ofrecen una visión agregada. La primera resume cada competición y temporada, con sus principales magnitudes y una serie de *rankings* de jugadores configurables por estadística, tanto en totales como normalizados por noventa minutos. Incorpora asimismo una comparación de la evolución del salario real y del estimado a lo largo de las temporadas, que permite observar si una liga o un club determinado paga por encima de lo que su rendimiento sugiere. La segunda ofrece el mismo tipo de análisis a escala de club, con el resumen de la plantilla y el detalle jugador a jugador de su desajuste salarial.

Por último, el *Comparador* enfrenta los perfiles de dos futbolistas de la misma posición, superponiendo sus diagramas de radar y detallando sus percentiles por faceta del juego, lo que facilita valorar sus fortalezas relativas de un solo vistazo.

En conjunto, la plataforma integra los tres componentes analíticos del trabajo. El modelo de regresión sustenta la valoración salarial que aparece en las fichas y en los análisis por liga y club, el sistema de similitud da forma al buscador de reemplazos, y los arquetipos etiquetan el estilo de cada jugador. De este modo, el proyecto no concluye con el entrenamiento de los modelos, sino que los transforma en una herramienta explorable, orientada al apoyo en la toma de decisiones deportivas.

4.4 Resultados del proyecto

Una vez descritas las distintas fases del desarrollo, esta sección recoge de forma consolidada los resultados obtenidos, poniéndolos en relación con las preguntas de investigación planteadas en la Sección 2.3. El objetivo no es reinterpretar aquí cada resultado, tarea que corresponde a la discusión (Capítulo 5), sino ofrecer una visión general de los resultados obtenidos.

La primera pregunta se refería a la posibilidad de estimar el salario bruto anual de un futbolista a partir de su rendimiento y sus variables contextuales. El modelo de regresión desarrollado responde afirmativamente. En su versión final, que combina las estadísticas de rendimiento con la trayectoria salarial reciente del jugador, explica en torno al 72 % de la variabilidad del salario sobre jugadores no vistos durante el entrenamiento. Aun cuando el modelo se apoya únicamente en el rendimiento, sin recurrir al historial salarial, mantiene una capacidad explicativa cercana al 60 %, lo que confirma que las estadísticas deportivas contienen una parte importante de la información que determina el salario.

La segunda pregunta planteaba si era posible detectar jugadores sobrepagados o infrapagados en relación con su rendimiento. El proyecto aborda esta cuestión mediante los residuos del modelo, es decir, la diferencia entre el salario real y el estimado. Este mecanismo permite señalar de forma sistemática a los futbolistas cuya remuneración se aparta de la que su rendimiento predice, tanto por encima como por debajo. Los casos con mayor desviación resultan coherentes con el conocimiento futbolístico, e identifican tanto perfiles de gran rendimiento y salario contenido como jugadores cuya ficha responde a factores ajenos al rendimiento observable.

La tercera pregunta abordaba la identificación de futbolistas similares y de perfiles de juego comparables mediante técnicas no supervisadas. En este punto el trabajo entrega dos resultados complementarios. Por un lado, un sistema de similitud que, dado un jugador, recupera

a los de estilo más parecido y permite orientar la búsqueda hacia alternativas más económicas. Por otro, una tipificación de los futbolistas en arquetipos por posición, que agrupa a los jugadores según su estilo de juego en perfiles interpretables. La validación cualitativa de ambos, contrastada con el criterio futbolístico, respalda que las representaciones obtenidas capturan el estilo de los jugadores y no un simple patrón estadístico.

La cuarta y última pregunta se refería a la integración de todo el análisis en una plataforma interactiva orientada a su uso práctico. El resultado es una aplicación web funcional, que reúne los tres componentes anteriores en una interfaz accesible. A través de sus distintas secciones, la plataforma permite consultar la valoración salarial de cada jugador, buscar reemplazos de perfil similar, explorar ligas y clubes, y comparar futbolistas entre sí, transformando así los modelos en una herramienta explorable.

En conjunto, los cuatro objetivos planteados al inicio del trabajo quedan cubiertos. El proyecto entrega un modelo de regresión salarial con una capacidad explicativa notable, un mecanismo de detección de desajustes salariales, un sistema de similitud y de arquetipos entre jugadores, y una plataforma que integra todo ello en una herramienta de consulta. La valoración crítica de estos resultados, sus limitaciones y sus implicaciones se desarrollan en los capítulos siguientes.

4.5 Recursos, presupuesto y viabilidad

El desarrollo del proyecto se ha apoyado de forma deliberada en herramientas de código abierto y servicios de acceso gratuito, lo que ha permitido cubrir todo el ciclo de trabajo sin coste económico directo. El análisis se ha llevado a cabo en Python, con Visual Studio Code como entorno de desarrollo y cuadernos Jupyter para el trabajo iterativo, empleando bibliotecas libres como *pandas*, *scikit-learn*, XGBoost, *matplotlib* o *plotly*. El control de versiones se ha gestionado con Git y GitHub, y la plataforma final se ha desplegado en Streamlit Community Cloud, cuyo plan gratuito basta para publicar la aplicación a partir del repositorio del proyecto. Los datos proceden de fuentes de consulta pública, obtenidas mediante *web scraping*. En cuanto al hardware, todo el trabajo se ha realizado en un equipo personal, sin necesidad de infraestructura especializada.

Por tanto, el presupuesto real del proyecto es nulo en lo que respecta a licencias e infraestructura. No obstante, resulta ilustrativo estimar el coste que tendría trasladar el proyecto a un entorno en la nube de pago, por ejemplo si se quisiera ejecutar y mantener el *pipeline* en un servidor dedicado de Amazon Web Services. Una instancia de tipo *t3.large* (2 vCPU y 8 GiB de memoria), suficiente para ejecutar los cuadernos y servir la aplicación, tiene un coste bajo demanda de aproximadamente 0,085 \$ por hora en la región de Europa [28]. Suponiendo un funcionamiento continuo, esto supondría en torno a 62 \$ mensuales, unos 60 € al cambio, a los que habría que añadir un pequeño coste de almacenamiento.

La viabilidad del trabajo queda así respaldada por partida doble. Por un lado, su desarrollo ha sido plenamente realizable con recursos gratuitos y un equipo personal, lo que lo hace reproducible por cualquier persona sin inversión económica. Por otro, su eventual traslado a un entorno profesional en la nube tendría un coste asumible, lo que confirma que la solución es sostenible también en un escenario de explotación real.

4.6 **Ética y compromiso social**

Este trabajo se alinea con los principios de igualdad de género y respeto a la diversidad. Se ha desarrollado garantizando un entorno de trabajo seguro, con tolerancia cero hacia cualquier forma de discriminación. Asimismo, reconoce la aportación histórica de las mujeres al desarrollo del deporte y de la ciencia de datos, integrando una perspectiva de equidad en el tratamiento de los datos y en el análisis realizado, y asegurando que la metodología desarrollada pueda aplicarse por igual al fútbol masculino y femenino, respetando sus particularidades.

Capítulo 5. DISCUSIÓN

Una vez presentados los resultados, este capítulo los somete a una lectura crítica. Se valora la calidad real de la predicción salarial, se examina si el modelo identifica desajustes reconocibles del mercado y se exponen las limitaciones del estudio.

5.1 Calidad de la predicción salarial

La capacidad explicativa del modelo debe interpretarse con cautela, distinguiendo sus dos componentes. El modelo basado únicamente en rendimiento, con un coeficiente de determinación en torno al 60 %, ofrece una medida más honesta de hasta qué punto las estadísticas deportivas explican el salario. El salto hasta el 72 % del modelo completo procede en gran medida del salario de la temporada anterior, que es con diferencia la variable más influyente. Conviene ser transparente sobre lo que esto significa. Buena parte del acierto del modelo completo no proviene de descubrir el valor de un jugador a partir de su juego, sino de la fuerte inercia del propio salario, ya que quien cobraba mucho el año anterior tiende a seguir cobrando mucho. Lejos de ser un defecto, este comportamiento refleja una realidad del mercado, pero obliga a no confundir la capacidad predictiva del modelo con una supuesta cuantificación objetiva del rendimiento.

Esta distinción es coherente con el planteamiento del trabajo. El modelo sin histórico responde a la pregunta de cuánto del salario explica el rendimiento, mientras que el modelo con histórico persigue la mejor predicción posible del salario, que es lo que resulta útil en una herramienta de apoyo. Ambos son valiosos, pero responden a preguntas distintas, y mantenerlos separados evita atribuir al rendimiento un poder explicativo mayor del que realmente tiene.

5.2 Detección de desajustes salariales

El aspecto más revelador del modelo no es su precisión agregada, sino su comportamiento en los casos que no acierta. Los residuos de mayor magnitud, lejos de ser errores aleatorios, se concentran en jugadores cuyo salario responde a factores ajenos al rendimiento observable, lo que constituye una forma de validación indirecta. Entre los futbolistas señalados como sobrepagados aparecen estrellas consagradas y jóvenes de gran proyección, cuya remuneración incorpora reputación, valor de mercado o expectativas de futuro que el modelo, por diseño, no puede ver. Entre los infrapagados figuran perfiles de alto rendimiento en clubes modestos, así como situaciones singulares por completo ajenas a la lógica deportiva, como la de un jugador veterano que acepta un salario simbólico por regresar a su club de origen.

Que estos casos sean reconocibles e interpretables sin conocimiento previo del modelo respalda la utilidad del enfoque. El sistema no pretende dictar cuál debería ser el salario de un jugador, sino señalar aquellos cuya ficha se aparta de lo que su rendimiento anticipa, dejando la interpretación final al criterio experto. En este sentido, los residuos funcionan menos como una medida de error y más como un detector de anomalías dignas de atención.

5.3 Limitaciones del estudio

El trabajo presenta varias limitaciones que conviene reconocer explícitamente. La primera afecta a la variable objetivo. Los salarios de Capology no son cifras oficiales, sino estimaciones, y solo una parte aparece verificada en la fuente, por lo que el modelo aprende sobre una aproximación al salario real y no sobre el dato exacto. Aunque se ha asumido como la mejor referencia disponible, cualquier sesgo sistemático de la fuente se traslada al modelo.

Una segunda limitación es de carácter temporal. Los datos de la temporada en curso se recogieron antes de su finalización, en concreto el 28 de abril, mientras que las competiciones no concluyeron hasta el 23 de mayo, de modo que las estadísticas de esa temporada están ligeramente incompletas respecto a las ya cerradas. A ello se suma que las métricas avanzadas de goles y asistencias esperadas no están disponibles en las dos primeras temporadas del estudio, lo que limita su aprovechamiento pese a su valor analítico.

La integración de datos introduce una tercera fuente de incertidumbre. El emparejamiento entre fuentes, al basarse en la similitud de los nombres, no está exento de errores, y la política deliberadamente conservadora adoptada, que prefiere dejar a un jugador sin salario antes que asignarle uno erróneo, reduce los emparejamientos incorrectos pero a costa de perder parte de las observaciones. El filtrado por minutos mínimos mitiga este efecto, ya que eleva la cobertura salarial hasta prácticamente la totalidad de la muestra analizada, pero la limitación subsiste en el conjunto de partida.

Por último, el estudio se centra en el salario y no incorpora el valor de mercado del jugador, una variable estrechamente relacionada que podría enriquecer el análisis. Su ausencia es una decisión de alcance que implica que factores como el potencial de revalorización de un futbolista quedan fuera del modelo y contribuyen a explicar algunos de los desajustes observados.

5.4 Comparación con las expectativas

Los resultados obtenidos se ajustan razonablemente a lo que cabía esperar al inicio del trabajo. La hipótesis de que el rendimiento explica una gran parte, pero no la totalidad, del salario queda confirmada. Frente a los trabajos centrados en el valor de mercado o en el precio de traspaso, la elección del salario bruto anual como objetivo sitúa a este proyecto en un terreno menos explorado, orientado al coste recurrente que asume el club en lugar del precio puntual de una operación.

La aportación diferencial del trabajo no reside tanto en la precisión del modelo de regresión, comparable a la de enfoques similares, como en la combinación de esa estimación con un sistema de similitud y una tipificación por arquetipos, y en su integración en una herramienta explorable. Esta perspectiva, que pasa de la predicción individual al apoyo a la toma de decisiones, es la que distingue el enfoque adoptado y la que sienta las bases para las conclusiones y las líneas de mejora que se abordan a continuación.

Capítulo 6. CONCLUSIONES

Este capítulo recoge las conclusiones del trabajo. En primer lugar se valora el grado de cumplimiento de los objetivos y se resumen los principales hallazgos, y a continuación se ofrece una reflexión personal sobre el proceso y los aprendizajes obtenidos.

6.1 Conclusiones del trabajo

El objetivo general del proyecto era construir una plataforma de análisis de la valoración salarial de futbolistas basada en su rendimiento, y puede afirmarse que se ha cumplido en su totalidad. Los objetivos específicos se han abordado uno a uno, desde la ingesta de datos de fuentes dispares hasta el despliegue de una aplicación pública, pasando por la integración, el análisis exploratorio, el modelado y el sistema de similitud, materializando el recorrido completo del *pipeline* tal como se planteó al inicio.

Entre los hallazgos principales destaca que el rendimiento deportivo explica una parte importante del salario, pero no su totalidad. La fracción no explicada se corresponde con factores como la reputación, el valor de mercado o las expectativas de futuro, cuya huella se manifiesta con claridad en los desajustes detectados. Se ha comprobado además que la inercia salarial es el factor más determinante en la predicción, y que las técnicas no supervisadas capturan el estilo de juego de un futbolista a partir únicamente de sus estadísticas, hasta reconstruir por sí solas las facetas del juego y los perfiles reconocibles de cada posición.

La aportación diferencial del trabajo reside en su carácter integrador, al combinar la estimación salarial con la detección de desajustes, la búsqueda de perfiles similares y la identificación de arquetipos en una única herramienta explorable. La elección del salario bruto anual como objetivo, en lugar del valor de mercado, orienta además el análisis hacia el coste recurrente de las plantillas, de utilidad directa en la gestión deportiva. El resultado no pretende sustituir el criterio experto, sino ofrecer un apoyo estructurado y objetivo para explorar la relación entre rendimiento y remuneración.

6.2 Conclusiones personales

En el plano personal, el trabajo ha supuesto la oportunidad de recorrer de principio a fin un proyecto de ciencia de datos completo. A diferencia de un ejercicio académico acotado, ha sido necesario partir de un problema abierto, obtener los datos por medios propios y sostener cada elección a lo largo de todas las fases, lo que ha permitido comprobar que la mayor parte del esfuerzo reside en la preparación y la integración de los datos más que en el modelado en sí.

La integración de dos fuentes sin un identificador común ha sido probablemente el mayor reto técnico, resuelto con una solución que combina automatización y revisión manual. También ha resultado formativo aprender a evaluar los modelos con rigor, evitando las fugas de información y resistiendo la tentación de perseguir una métrica alta a costa de la validez. Más allá de las herramientas concretas, el aprendizaje más valioso ha sido desarrollar una forma de trabajo más crítica y autónoma, basada en tomar decisiones razonadas, validarlas empíricamente y comunicarlas con claridad.

Capítulo 7. FUTURAS LÍNEAS DE TRABAJO

El trabajo desarrollado admite diversas ampliaciones que permitirían superar algunas de sus limitaciones y enriquecer sus capacidades. A continuación se describen las líneas que se consideran más prometedoras.

Una primera dirección natural es la incorporación de datos en tiempo real. En su versión actual, la ingesta se realiza por lotes sobre los totales acumulados de cada temporada, lo que ofrece una fotografía estática que queda desactualizada a medida que avanza la competición. Sustituir este esquema por una actualización periódica y automática mantendría la plataforma permanentemente al día y permitiría seguir la evolución de los jugadores dentro de una misma temporada, en lugar de esperar a su cierre.

En segundo lugar, el estudio podría ampliarse a más ligas y temporadas. La cobertura actual, centrada en las seis grandes competiciones europeas durante seis campañas, podría extenderse a otras ligas o a un horizonte temporal más amplio. Esta ampliación aumentaría el volumen y la diversidad de los datos, mejoraría la representatividad del modelo y permitiría analizar mercados hasta ahora no cubiertos, así como los movimientos de jugadores entre competiciones distintas.

Una tercera línea, especialmente relevante, es la integración del valor de mercado del futbolista como una variable adicional o como un segundo objetivo del modelo. La ausencia de esta información es una de las limitaciones reconocidas del trabajo, ya que el valor de mercado recoge buena parte de los factores intangibles que el modelo salarial no observa. Incorporarlo, a partir de fuentes como Transfermarkt, permitiría contrastar salario y valoración de mercado y ofrecer una imagen más completa de la situación económica de cada jugador.

En cuarto lugar, resultaría de interés desarrollar modelos de evolución temporal del jugador. El enfoque actual trata cada temporada de forma independiente, sin modelar explícitamente la trayectoria del futbolista a lo largo del tiempo. Un planteamiento orientado a las series temporales permitiría anticipar la evolución del rendimiento y del salario de un jugador, lo que abriría la puerta a análisis de tipo predictivo sobre su progresión futura, de gran valor en la planificación deportiva a medio plazo.

Por último, la plataforma podría enriquecerse con un asistente conversacional que permitiera consultar la información mediante lenguaje natural. Apoyado en un modelo de lenguaje a través de su interfaz de programación, este asistente facilitaría formular preguntas directas sobre jugadores, comparar perfiles o solicitar recomendaciones sin necesidad de navegar por las distintas secciones, acercando la herramienta a un público aún más amplio.

En conjunto, estas líneas comparten un mismo horizonte, el de transformar la solución actual en un sistema más completo, dinámico y accesible, capaz de acompañar de forma continua las decisiones en el ámbito de la gestión deportiva.

Bibliografía

- [1] W. Spearman, «Beyond expected goals,» en *Proceedings of the 12th MIT sloan sports analytics conference*, 2018, págs. 1-17.
- [2] J. Gudmundsson y M. Horton, «Spatio-temporal analysis of team sports,» *ACM Computing Surveys (CSUR)*, vol. 50, n.º 2, págs. 1-34, 2017.
- [3] Transfermarkt. «Transfermarkt: Valores de mercado, transferencias y estadísticas de fútbol. »dirección: <https://www.transfermarkt.es>.
- [4] CIES Football Observatory. «CIES Football Observatory: Análisis, informes y datos del fútbol profesional. »dirección: <https://football-observatory.com/?lang=en>.
- [5] J. Molina Prieto y M. F. Bedoya Cuitiva, «Análisis de los precios de jugadores en el mercado de fichajes y su impacto económico y financiero en los principales equipos del fútbol europeo: 2015 al 2022,» 2023.
- [6] D. Malikov, P. Jung y J. Kim, «Predicting Soccer Player Salaries with Both Traditional and Automated Machine Learning Approaches,» *Applied Sciences*, vol. 15, n.º 14, pág. 8108, 2025.
- [7] Y. Li, A. Ayanso, S. Yuan, M. Kusy y S. Kerwin, «When interpretable machine learning meets the beautiful game: a predictive analytics approach to soccer player valuation in the transfer market,» *Sport, Business and Management: An International Journal*, vol. 16, n.º 2, págs. 240-261, 2026.
- [8] J. Reis y M. Housley, *Fundamentals of data engineering*. "O'Reilly Media, Inc.", 2022.
- [9] A. Chapagain, *Hands-On Web Scraping with Python: Perform advanced scraping operations using various Python libraries and tools such as Selenium, Regex, and others*. Packt Publishing Ltd, 2019.
- [10] A. Fornieles, «Transformaciones de datos en la elaboración de estudios salariales,» *Revista de Psicología del Trabajo y de las Organizaciones*, vol. 29, n.º 2, págs. 75-82, 2013.
- [11] A. Sánchez Alberca, *Manual de Estadística para Ciencias e Ingenierías*, Bajo licencia Creative Commons BY-NC-SA.
- [12] D. M. Diez, C. D. Barr y M. Cetinkaya-Rundel, *OpenIntro statistics*. OpenIntro Boston, MA, USA: 2012, vol. 4.
- [13] T. Hastie, R. Tibshirani, J. Friedman et al., *The elements of statistical learning*, 2009.
- [14] F. Zhengxin et al., «Mlops spanning whole machine learning life cycle: A survey,» *arXiv preprint arXiv:2304.07296*, 2023.
- [15] M. Kuhn y K. Johnson, *Feature engineering and selection: A practical approach for predictive models*. Chapman y Hall/CRC, 2019.
- [16] T. Chen y C. Guestrin, «XGBoost: A Scalable Tree Boosting System,» en *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, págs. 785-794. DOI: 10.1145/2939672.2939785.

- [17] P. J. Rousseeuw, «Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis,» *Journal of Computational and Applied Mathematics*, vol. 20, págs. 53-65, 1987. DOI: 10.1016/0377-0427(87)90125-7.
- [18] G. James, D. Witten, T. Hastie, R. Tibshirani et al., *An introduction to statistical learning: with applications in R*. Springer, 2013, vol. 103.
- [19] K. P. Murphy, *Probabilistic Machine Learning: An introduction*. MIT Press, 2022. dirección: <http://probml.github.io/book1>.
- [20] O. Seymour. «ScraperFC: A Python Package for Scraping Football Data. »dirección: <https://scraperfc.readthedocs.io>.
- [21] Sofascore. «Sofascore: Resultados, estadísticas y datos de fútbol. »dirección: <https://www.sofascore.com>.
- [22] Capology. «Capology: Salarios y finanzas del fútbol profesional. »dirección: <https://www.capology.com>.
- [23] I. Amón y C. Jiménez, «Funciones de similitud sobre cadenas de texto: una comparación basada en la naturaleza de los datos,» en *CONF-IRM Proceedings*, vol. 58, 2010.
- [24] M. Bachmann, *RapidFuzz: Rapid fuzzy string matching in Python*, <https://rapidfuzz.github.io/RapidFuzz/Usage/distance/Indel.html>.
- [25] P. F. Muñoz, L. M. Escobar y T. S. Acalo, «Estudio de potencia de pruebas de normalidad usando distribuciones desconocidas con distintos niveles de no normalidad,» *Perfiles*, vol. 1, n.º 21, págs. 4-11, 2019.
- [26] T. Akiba, S. Sano, T. Yanase, T. Ohta y M. Koyama, «Optuna: A Next-Generation Hyperparameter Optimization Framework,» en *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2019, págs. 2623-2631. DOI: 10.1145/3292500.3330701.
- [27] Streamlit Inc., *Streamlit: A faster way to build and share data apps*, <https://streamlit.io>.
- [28] Amazon Web Services, *Amazon EC2 On-Demand Pricing*, <https://aws.amazon.com/ec2/pricing/on-demand/>.

Capítulo 8. ANEXOS

Este capítulo recoge material complementario que, por su extensión o su carácter de referencia, se ha separado del cuerpo principal de la memoria. Se incluye en concreto el diccionario completo de las variables empleadas en el trabajo, al que se remite desde las distintas fases del desarrollo.

8.1 Diccionario de variables

Con el fin de reforzar la trazabilidad y la reproducibilidad del trabajo, se documenta a continuación la totalidad de las variables ingestadas de las dos fuentes de datos. Para cada una se indica su nombre original y una breve descripción de su significado, de modo que cualquier referencia a una variable concreta a lo largo de la memoria pueda contrastarse con su definición de origen.

8.1.1. Diccionario de variables de Sofascore

La Tabla 8.1 recoge las variables de rendimiento extraídas de Sofascore, agrupadas por facetas del juego para facilitar su consulta.

Tabla 8.1. Diccionario de las variables extraídas de Sofascore.

Variable	Descripción
<i>Participación y valoración</i>	
appearances	Partidos disputados
matchesStarted	Partidos como titular
minutesPlayed	Minutos jugados
rating	Valoración media del jugador (Sofascore)
countRating	Número de partidos con valoración registrada
totalRating	Suma de las valoraciones de los partidos
totwAppearances	Apariciones en el equipo de la semana
<i>Producción ofensiva</i>	
goals	Goles
assists	Asistencias
goalsAssistsSum	Suma de goles y asistencias
expectedGoals	Goles esperados (xG)
expectedAssists	Asistencias esperadas (xA)
bigChancesCreated	Ocasiones claras creadas
bigChancesMissed	Ocasiones claras falladas
keyPasses	Pases clave (que generan un remate)
passToAssist	Pases que preceden a una asistencia (pre-asistencia)
totalAttemptAssist	Pases que terminan en un remate del compañero
<i>Finalización</i>	
totalShots	Remates totales
shotsOnTarget	Remates a puerta
shotsOffTarget	Remates fuera
blockedShots	Remates propios bloqueados por un rival
hitWoodwork	Remates al palo o larguero

continúa en la página siguiente

Tabla 8.1 – *continuación*

Variable	Descripción
goalConversionPercentage	Porcentaje de conversión de remates en gol
scoringFrequency	Frecuencia goleadora (minutos por gol)
shotsFromInsideTheBox	Remates desde dentro del área
shotsFromOutsideTheBox	Remates desde fuera del área
goalsFromInsideTheBox	Goles dentro del área
goalsFromOutsideTheBox	Goles fuera del área
headedGoals	Goles de cabeza
leftFootGoals	Goles con la pierna izquierda
rightFootGoals	Goles con la pierna derecha
freeKickGoal	Goles de falta directa
shotFromSetPiece	Remates a balón parado
setPieceConversion	Conversión en acciones a balón parado
<i>Penaltis</i>	
penaltyGoals	Goles de penalti
penaltiesTaken	Penaltis lanzados
penaltyConversion	Porcentaje de penaltis transformados
penaltyWon	Penaltis provocados
penaltyConceded	Penaltis cometidos
attemptPenaltyTarget	Penaltis lanzados a portería
attemptPenaltyMiss	Penaltis lanzados fuera
attemptPenaltyPost	Penaltis lanzados al poste
<i>Pase</i>	
totalPasses	Pases intentados
accuratePasses	Pases completados
accuratePassesPercentage	Porcentaje de pases completados
inaccuratePasses	Pases fallados
accurateFinalThirdPasses	Pases completados en el último tercio
accurateOwnHalfPasses	Pases completados en campo propio
totalOwnHalfPasses	Pases intentados en campo propio
accurateOppositionHalfPasses	Pases completados en campo rival
totalOppositionHalfPasses	Pases intentados en campo rival
accurateLongBalls	Balones largos completados
accurateLongBallsPercentage	Porcentaje de balones largos completados
totalLongBalls	Balones largos intentados
accurateChippedPasses	Pases picados completados
totalChippedPasses	Pases picados intentados
accurateCrosses	Centros completados
accurateCrossesPercentage	Porcentaje de centros completados
totalCross	Centros intentados
<i>Regate y conducción</i>	
successfulDribbles	Regates completados
successfulDribblesPercentage	Porcentaje de regates completados
totalContest	Regates intentados
touches	Toques de balón
dispossessed	Pérdidas por desposesión (le roban el balón)
possessionLost	Pérdidas de posesión
possessionWonAttThird	Recuperaciones en el último tercio
ballRecovery	Recuperaciones de balón
<i>Acciones defensivas</i>	
tackles	Entradas

continúa en la página siguiente

Tabla 8.1 – *continuación*

Variable	Descripción
tacklesWon	Entradas ganadas
tacklesWonPercentage	Porcentaje de entradas ganadas
interceptions	Intercepciones
clearances	Despejes
outfielderBlocks	Bloqueos realizados (jugador de campo)
dribbledPast	Veces superado en regate por un rival
errorLeadToShot	Errores que acaban en remate rival
errorLeadToGoal	Errores que acaban en gol rival
<i>Duelos</i>	
totalDuelsWon	Duelos totales ganados
totalDuelsWonPercentage	Porcentaje de duelos totales ganados
duelLost	Duelos perdidos
groundDuelsWon	Duelos por tierra ganados
groundDuelsWonPercentage	Porcentaje de duelos por tierra ganados
aerialDuelsWon	Duelos aéreos ganados
aerialDuelsWonPercentage	Porcentaje de duelos aéreos ganados
aerialLost	Duelos aéreos perdidos
<i>Portería</i>	
saves	Paradas
savesCaught	Paradas con bloqueo
savesParried	Paradas con rechace
savedShotsFromInsideTheBox	Paradas a remates desde dentro del área
savedShotsFromOutsideTheBox	Paradas a remates desde fuera del área
goalsPrevented	Goles evitados (xG en contra menos goles encajados)
cleanSheet	Partidos sin encajar (portería a cero)
goalsConceded	Goles encajados
goalsConcededInsideTheBox	Goles encajados dentro del área
goalsConcededOutsideTheBox	Goles encajados fuera del área
penaltySave	Penaltis detenidos
penaltyFaced	Penaltis enfrentados
highClaims	Balones aéreos atrapados
crossesNotClaimed	Centros no atrapados
punches	Despejes de puños
runsOut	Salidas del portero
successfulRunsOut	Salidas exitosas del portero
goalKicks	Saques de puerta
<i>Disciplina</i>	
fouls	Faltas cometidas
wasFouled	Faltas recibidas
offsides	Fueras de juego
yellowCards	Tarjetas amarillas
yellowRedCards	Expulsiones por doble amarilla
redCards	Tarjetas rojas
directRedCards	Tarjetas rojas directas
ownGoals	Goles en propia puerta
<i>Identificadores y metadatos</i>	
player	Nombre del jugador
team	Equipo del jugador
player id	Identificador único de jugador en Sofascore
team id	Identificador único de equipo en Sofascore

continúa en la página siguiente

Tabla 8.1 – *continuación*

Variable	Descripción
data_country	Metadato: liga o país de procedencia
data_season	Metadato: temporada

8.1.2. Diccionario de variables de Capology

La Tabla 8.2 detalla los campos obtenidos de Capology, que aportan la información salarial y una serie de atributos descriptivos de cada jugador.

Campo	Descripción
PLAYER	Nombre del jugador
GROSS P/W (EUR)	Salario bruto semanal, en euros
GROSS P/Y (EUR)	Salario bruto anual, en euros (variable objetivo)
ADJ. GROSS (EUR)	Salario bruto ajustado, en euros
POS.	Posición del jugador
AGE	Edad
COUNTRY	Nacionalidad
CLUB	Club
data_country	Metadato: liga o país de procedencia
data_season	Metadato: temporada

Tabla 8.2. Diccionario de los campos obtenidos de Capology.